COMID

WEEK 09 · 차시 9-1 ~ 9-3 · 50분

기계학습 (1) 표현자와 대리모델

분자 표현자와 feature library · XGBoost 대리모델 · SHAP 해석

윤태영 (Taeyoung Yun)

실습 · XGBoost + SHAP

퀴즈 9주차

RECAP · WEEK 08

지난 주차 요약과 이번 주차의 위치

8주차

클링커 모델 · ReaxFF 수화 · C-S-H(calcium silicate hydrate) 물성 · ML 퍼텐셜 — 두 소재의 MD 물성 계산 완료

남은 질문

MD 1회 계산 비용 큼 — 후보 조성 전체를 계산하지 않고 물성 예측 가능 여부

이번 주차

분자 표현자(molecular descriptor)로 조성 수치화 → XGBoost 대리모델(surrogate model)로 예측 → SHAP으로 해석

파이프라인 6단계 중 04 대리모델 학습의 첫 단계 — 트리 모델 기준선(baseline)

OBJECTIVE

9주차 학습목표

01 분자 표현자(RDKit · SMILES · 분자 지문 fingerprint) 계산과 특징 라이브러리(feature library) 구축

02 적절한 데이터 분할로 XGBoost(eXtreme Gradient Boosting) 대리모델 학습 · 검증

03 하이퍼파라미터(hyperparameter) 체계적 조정 · 과적합(overfitting) 신호 판별

04 SHAP(SHapley Additive exPlanations)으로 모델 예측 해석 · 특징 재정련

AGENDA

9주차 구성

9-1	표현자와 feature library	18분
9-2	XGBoost 대리모델	16분
9-3	SHAP 해석	16분

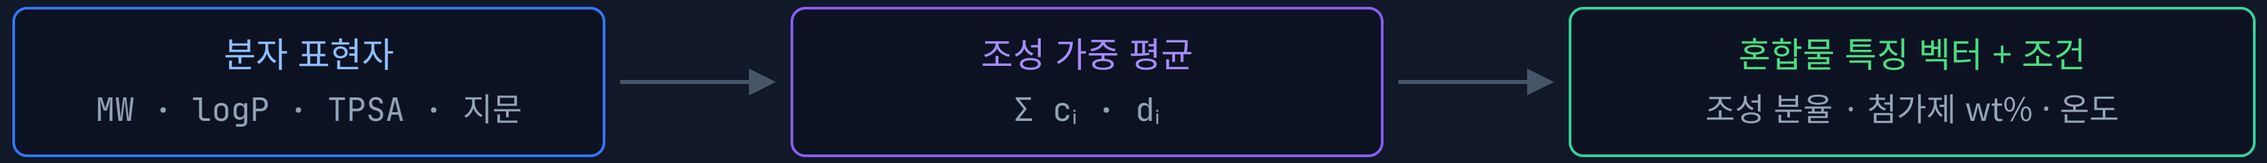
9-1

표현자와 feature library

18분 · RDKit · SMILES · fingerprint 표현자 계산 · 측정 가능 기술자 · 라이브러리 관리

9-1 · DESCRIPTORS

분자에서 혼합물 표현자로



표현자	내용	주의
물리화학 기술자(physicochemical descriptor)	분자량(MW) · logP(옥탄올-물 분배계수) · TPSA(topological polar surface area) · 방향족 분율 · 극성 원자 수	해석 용이 · 개수 적음
지문(ECFP, Extended-Connectivity Fingerprint)	부분구조(substructure) 존재 여부를 비트로 표시	차원이 커 작은 데이터에선 과적합
조성 변수	SARA(Saturate · Aromatic · Resin · Asphaltene) 분율 · 첨가제 함량	설계 변수와 직결 — 반드시 포함
구조 기술자	RDF(radial distribution function) 피크 · 자유부피(free volume) · 적층 크기	MD 계산 후에만 획득 — 예측 입력으로 부적합

9-1 · SMILES → RDKit

SMILES 한 줄에서 숫자 벡터까지

descriptors.py

```
from rdkit import Chem
from rdkit.Chem import Descriptors, AllChem

mol = Chem.MolFromSmiles("c1ccc2ccccc2c1")
```

```
d = dict(mw        = Descriptors.MolWt(mol),
         log_p     = Descriptors.MolLogP(mol),
         tpsa      = Descriptors.TPSA(mol),
         n_aro_ring = Descriptors.NumAromaticRings(mol))
```

```
fp = AllChem.GetMorganFingerprintAsBitVect(
         mol, radius=2, nBits=1024)   # ECFP4
```

```
row = {**d, **{f"fp{i}": b for i, b in enumerate(fp)}}
```

SMILES	SMILES(Simplified Molecular-Input Line-Entry System): 분자 구조의 문자열 한 줄 표기 — 3주차 SARA 대표 분자 · 7주차 첨가제 라이브러리 모두 이 형식
기술자	RDKit(오픈소스 화학정보학 라이브러리) 계산 · MW · logP · TPSA · 방향족 고리 수 — 해석 가능한 수십 개 수치
fingerprint	ECFP4 — 반경 2 이내 부분구조의 존재 여부를 1024 비트로 표시 · 해석 어려움 · 구조 차이에 민감
출력	분자 하나 = 표 한 줄 · 열 이름 고정 필요 (이후 병합 조건)

비트 수 증가 → 표현력 상승 · 작은 데이터에서는 과적합 — 1024에서 시작

9-1 · MEASURABLE DESCRIPTORS

실험으로 측정 가능한 분자 기술자 8종

기술자	물리 의미	실험 측정법
n_heavy · 분자 크기	무거운 원자(heavy atom) 수 ≈ 분자량	질량분석(MS, mass spectrometry) · GPC(gel permeation chromatography)
O_frac · hetero_frac	산소 · 헤테로원자(heteroatom) 분율	원소분석(elemental analysis, CHNOS)
HC_ratio	수소/탄소 원자비	원소분석 · ^{1}H NMR(nuclear magnetic resonance)
aromaticity_proxy	방향족성(aromaticity) · 결합 밀도 기반	^{13}C NMR 방향족성
Rg · aspect_ratio · κ²	회전반경(radius of gyration) · 종횡비(aspect ratio) · 형상 이방성(shape anisotropy)	분자 구조 · SAXS(small-angle X-ray scattering)

집계 방식

분자별 값 → 분자 개수 가중(count-weighted) 평균 → 혼합물 수준 특징

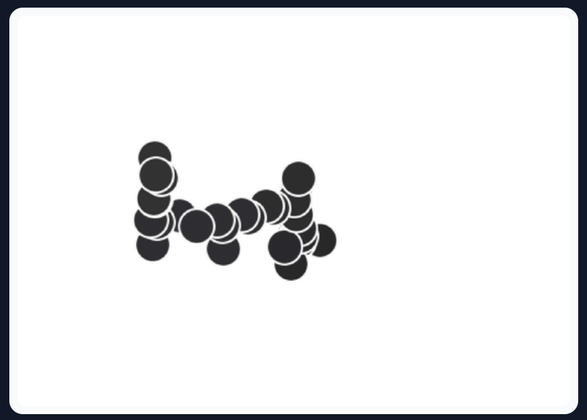
선정 기준

MD 계산값(e_intra) · 내부 라벨(aging) 제외 → 실험실 측정 가능한 입력만 사용

출처: COMID comid_experimental_descriptors.md (Claude Science, 2026-07-03)

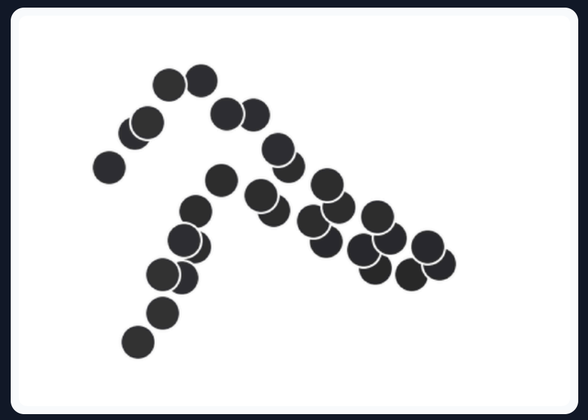
9-1 · SIZE & SHAPE

분자 크기 · 첨가제 형상의 수치화



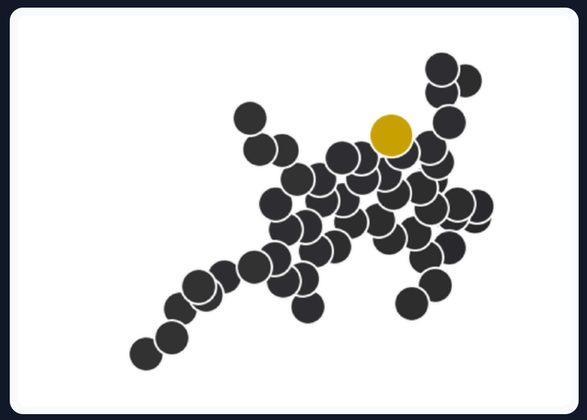
Squalane · 포화분(saturate)

무거운 원자 30



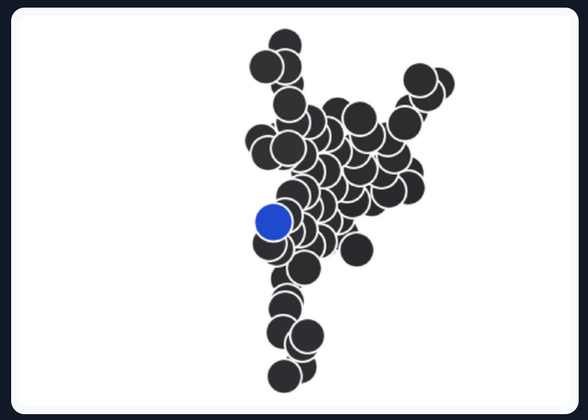
DOCHN · 방향족분(aromatic)

무거운 원자 30



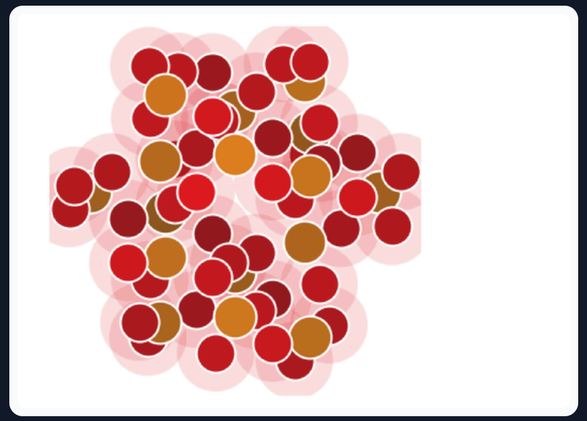
Thio · 아스팔텐(asphaltene)

무거운 원자 52



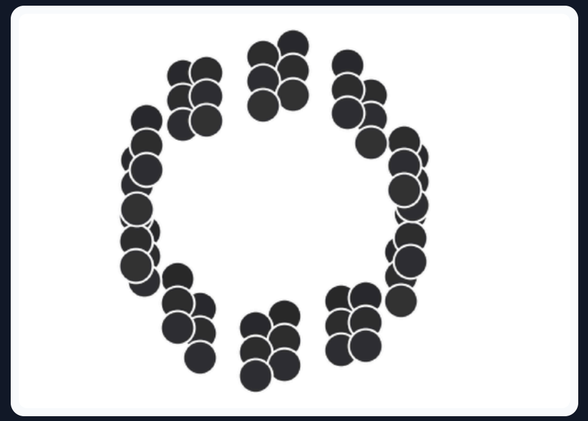
Pyrrole · 아스팔텐

무거운 원자 66



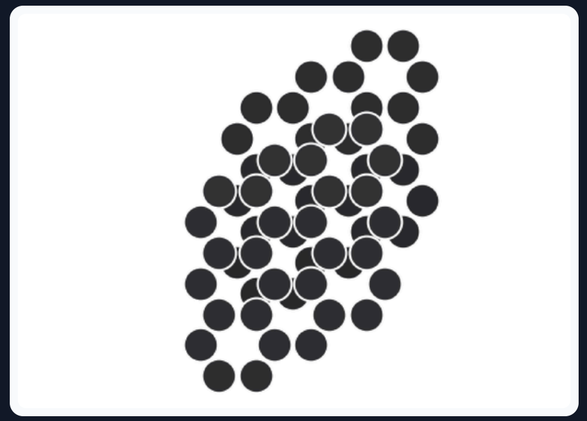
SiO_2 나노입자

종횡비 1 · ρ 2.65



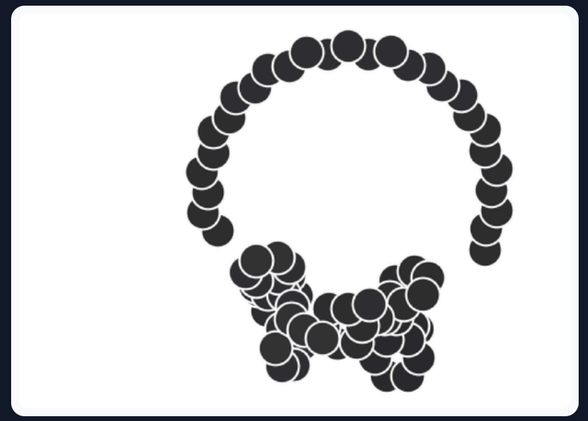
탄소나노튜브(CNT)

종횡비 100 · ρ 2.1



그래핀(graphene)

종횡비 50 · ρ 2.27



SBS(스티렌-부타디엔-스티렌)

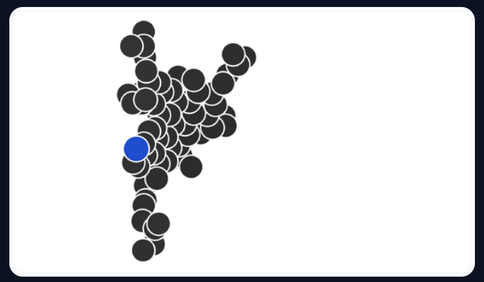
종횡비 10 · ρ 0.94

원자 색: 검정 C · 빨강 O · 파랑 N · 노랑 S · 주황 Si · ρ 단위 g/cm³ · 첨가제 값 = 문헌 대표값 · 그림: COMID fig_size_additive_features

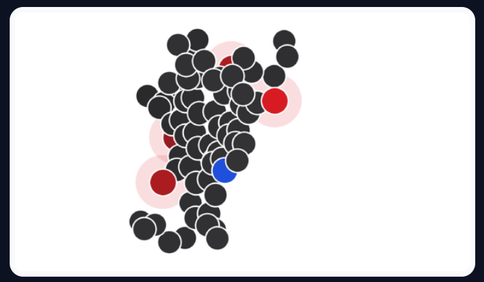
9-1 · OXIDATION INDEX

노화(aging) 정도 = 분자당 산소 원자 수

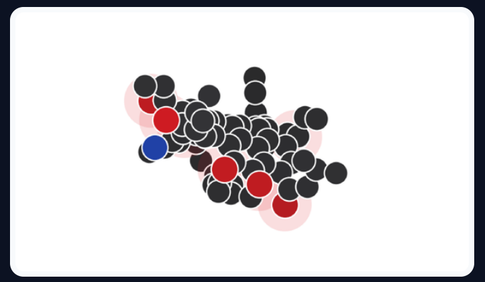
아스팔텐 AS-Pyrrole



비노화 NA · O 0

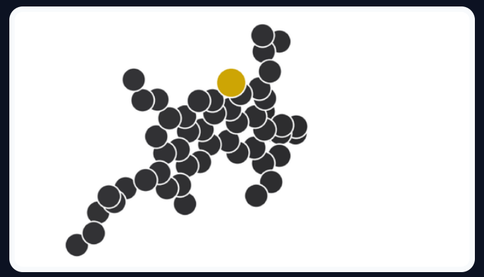


단기 SA · O 4

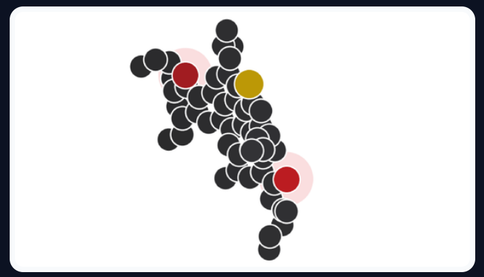


장기 LA · O 7

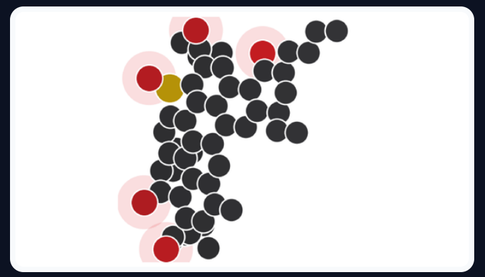
아스팔텐 AS-Thio



비노화 NA · O 0



단기 SA · O 2



장기 LA · O 5

원자 색: 검정 C · 빨강 O · 파랑 N · 노랑 S · 그림: COMID fig_molecular_structure

산화지수(oxidation index)

mol 파일의 O 원자 수 · 노화 시 카보닐(carbonyl) · 하이드록실(hydroxyl) 기 추가

바인더 O 분율(O-frac)

O 원자 수 / 전체 원자 수 — 원소분석으로 측정 가능

효과 · MD 계산값

산화지수 1 증가 → 밀도 +0.025 g/cm³ (회귀 기울기, 그림 주석값)

장점

라벨(NA · SA · LA) 대신 연속 수치 → 중간 노화 단계도 입력 가능

9-1 · REDUNDANCY

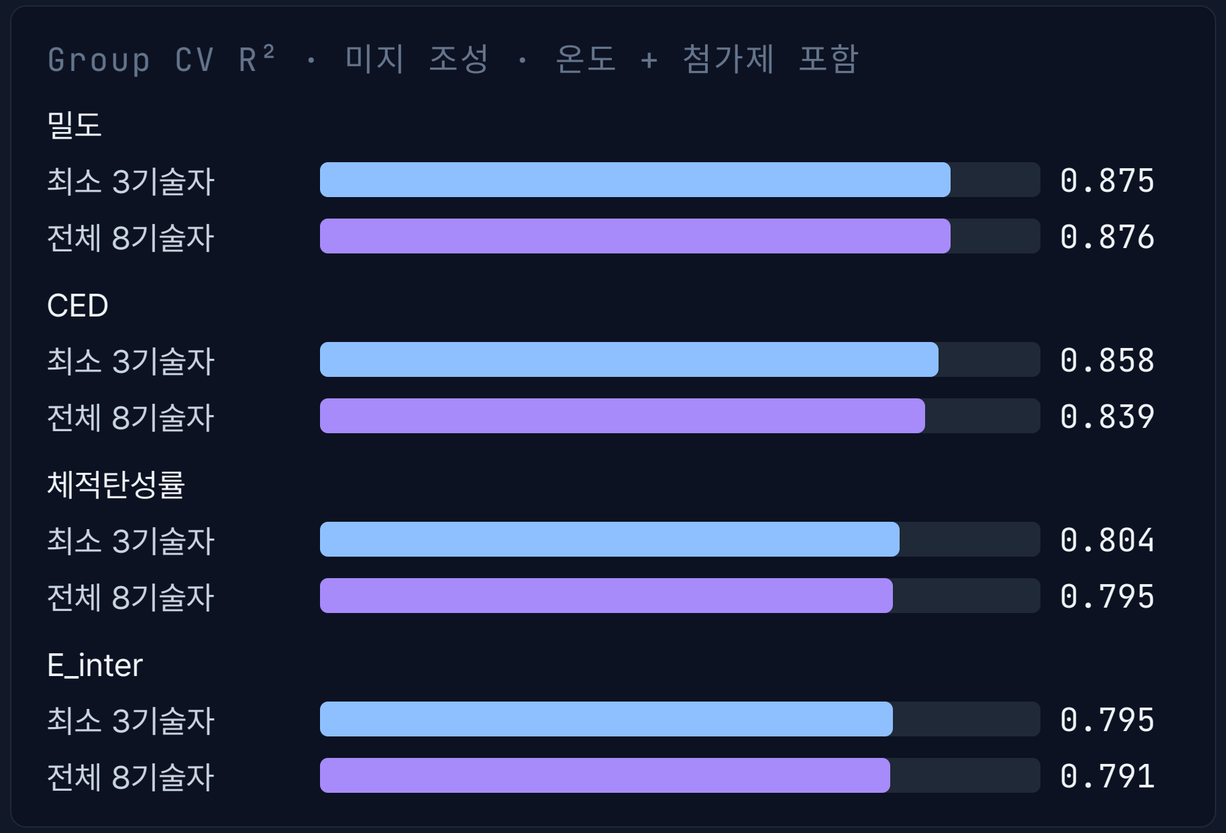
기술자 8개 → 3개: 중복 제거 후 성능 유지

중복 쌍 1
HC_ratio ≈ aromaticity_proxy · 상관계수 r = 0.96

중복 쌍 2
O_frac ≈ hetero_frac · 상관계수 r = 0.98

물성별 지배 기술자
밀도 = 헤테로 · O 분율 · E_inter = 분자 크기 · CED = O 분율

최소 3기술자
분자 크기(n_heavy) + 산소 분율(O_frac) + 종횡비(aspect_ratio) · 모두 실험 측정 가능



출처: COMID comid_experimental_descriptors.md · 막대 축 0 ~ 1

9-1 · FEATURE LIBRARY

feature library — 표현자 저장 · 재사용 · 버전 관리



한 번 계산, 여러 번 사용

분자 단위 표현자는 조성 변경과 무관 — 조성별 재계산 생략

버전 기록

RDKit 버전 · 비트 수 · 열 목록 기록 — 변경 시 모델 성능도 변화

MD 라벨과 조인 키

6주차 후처리 CSV의 실험 ID · 조성 ID로 결합 — 키 없으면 학습 행렬 구성 불가

누수(leakage) 방지

MD 계산 후에만 얻는 구조 기술자는 예측 입력에서 제외 — 설계 단계에 없는 값

9-1 · FEATURE CORRECTION

특징 재검토 사례: SARA 무효 · additive_wt 종속

01 · SARA 조성 4개

1차 특징 15개: 온도 · 첨가제 wt% · SARA 4 · 바인더 원핫(one-hot) 3 · 첨가제 원핫 6

SARA 중요도 ≈ 0 · CSV 확인: 672행 중 634행이 15 · 35 · 30 · 20 wt%로 동일

→ 변별력 없음 · 바인더 원핫이 대체

02 · additive_wt

첨가제 종류(원핫)로 additive_wt 예측 시 R^2 = 0.9996 → 독립 정보 없음

첨가제별 고정 wt%: CNT 4.17 · 그래핀 4.22 · SBS 5.57~5.90 · SiO_2 6.18 · 리그닌(lignin) 8.41

→ 제거 후 성능 동일: 밀도 0.973 → 0.974

03 · 원핫 → 분자특성

첨가제 원핫 대신 밀도 · 무기/유기 · 폴리머 여부 · 종횡비 · 강성 등급 · 나노 여부

원핫: 새 첨가제 = 새 열 → 예측 불가 · 분자특성: 값만 알면 예측 가능(외삽)

→ 역설계 목표를 물성값으로 지정 가능 (예: 밀도 2.5 · 고종횡비 필러)

점검 순서 변수의 실제 분포 확인 → 다른 특징으로 예측되는지 확인(종속성) → 물리 의미가 있는 값으로 대체

출처: COMID comid_modeling_report.md · comid_feature_correction.md · comid_core672_dataset.csv 직접 집계 · 첨가제 분자특성 = 문헌 대표값

9-2

XGBoost 대리모델

16분 · 트리 분할 · 부스팅 · 그룹 분할 검증 · 모델 비교

9-2 · WHY

GNN(그래프 신경망)보다 트리 모델을 먼저 쓰는 이유

데이터가 작다

MD 라벨은 수백~수천 건 · 표 형태 데이터에서 그래디언트 부스팅(gradient boosting) 우수

기준선이 필요

10주차 GNN이 이 기준선을 넘지 못하면 사용 근거 없음

해석

SHAP으로 물성 변화에 기여한 조성 변수 설명 가능

역설계에서는 "왜 그 조성인가"에 대한 설명 요구 빈번 — 해석 가능성 = 부가 기능이 아닌 요구사항

9-2 · DATASET

core672: MD 계산 672행 · 물리 범위 정제 대상

축	수준	행 수 (CSV 집계)
바인더	3	AAA1 274 · AAK1 199 · AAM1 199
첨가제	6	무첨가 166 · SBS 74 · CNT 108 · 그래핀 108 · 리그닌 108 · SiO_2 108
노화	3 + 미기록	NA 162 · SA 164 · LA 164 · 미기록 182 (CNT · SBS)
온도	12	213 ~ 433 K · 20 K 간격
타깃	4 + α	밀도 670 · CED 661 · 체적탄성률 626 · E_inter 576 · 점도 58 · Tg 45

CED 비물리값

음수(최소 −3123) 48행 → 제거 · 정제 후 CED group CV R^2 −75 → 0.71 (보고서)

체적탄성률 이상값

10 GPa 초과 50행 (최대 6.5×10^{27}) → 제거

중복 행

같은 조성 · 온도 · 밀도 반복 47행 (첫 행 제외 추가 사본 수 · 중복 묶음 전체 58행 · 최대 6회) → 무작위 분할 시 누수 원인

그룹 정의

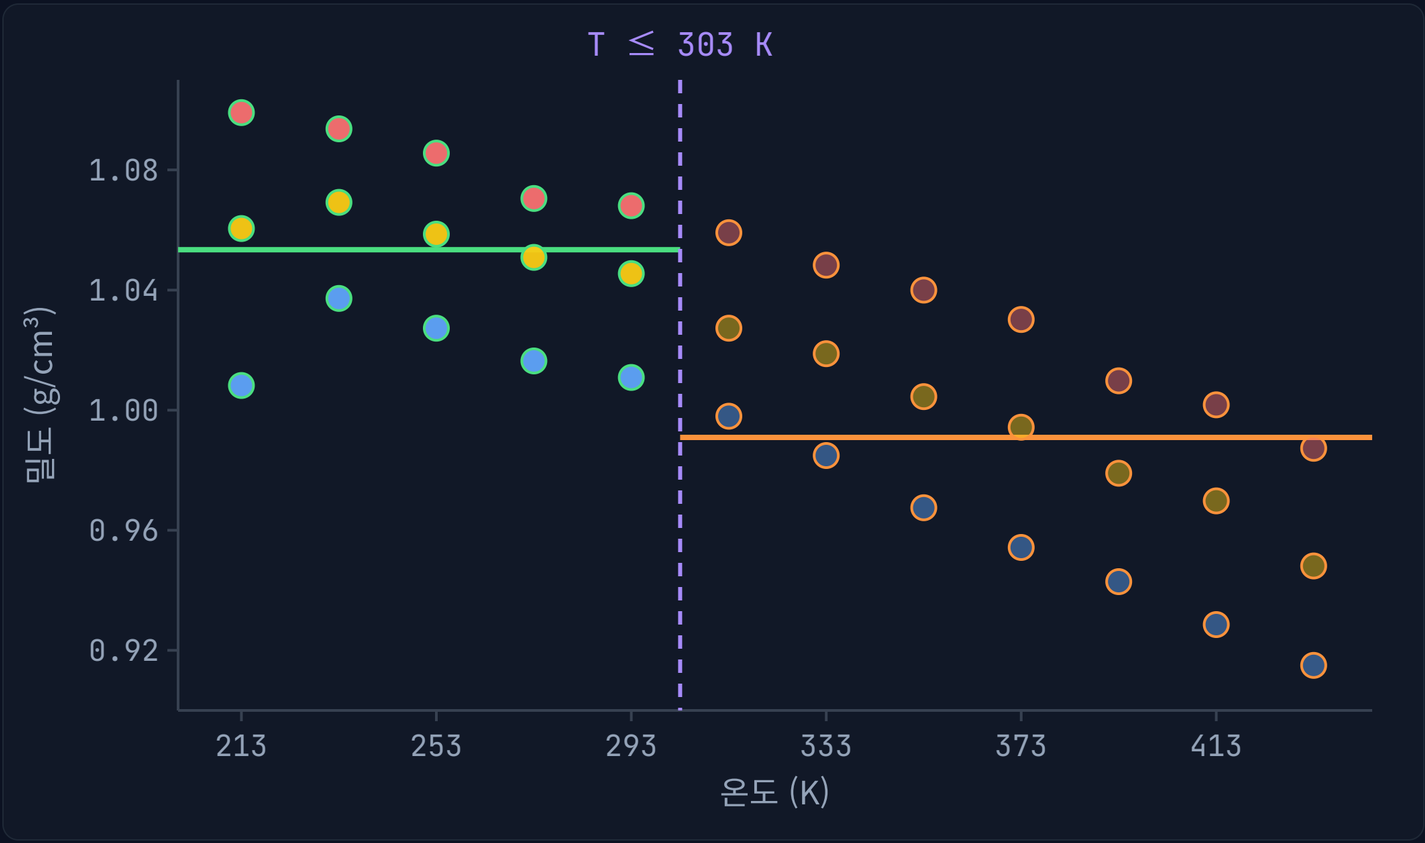
바인더 × 첨가제 × 노화 = 42개 조성 그룹 → 그룹 분할 단위

타깃 약어: CED(cohesive energy density, 응집에너지밀도) · E_inter(분자간 상호작용에너지) · Tg(유리전이온도) · 원천: COMID comid_core672_dataset.csv

9-2 · LIVE · SPLIT

결정 트리(decision tree) 분할: 임계값 이동 → 좌우 평균 · 오차 변화

분할 변수 | 온도 ⇄ 노화 | 임계값 ◀ ▶ | 최적 분할 | 데이터: core672 · AAA1 무첨가 36행 · 목표 = 밀도



● NA ● SA ● LA

분할 조건
온도 T ≤ 303 K

왼쪽 (진한 점)
n 15 · 평균 1.0534 · SSE 11.82

오른쪽 (흐린 점)
n 21 · 평균 0.9909 · SSE 31.03

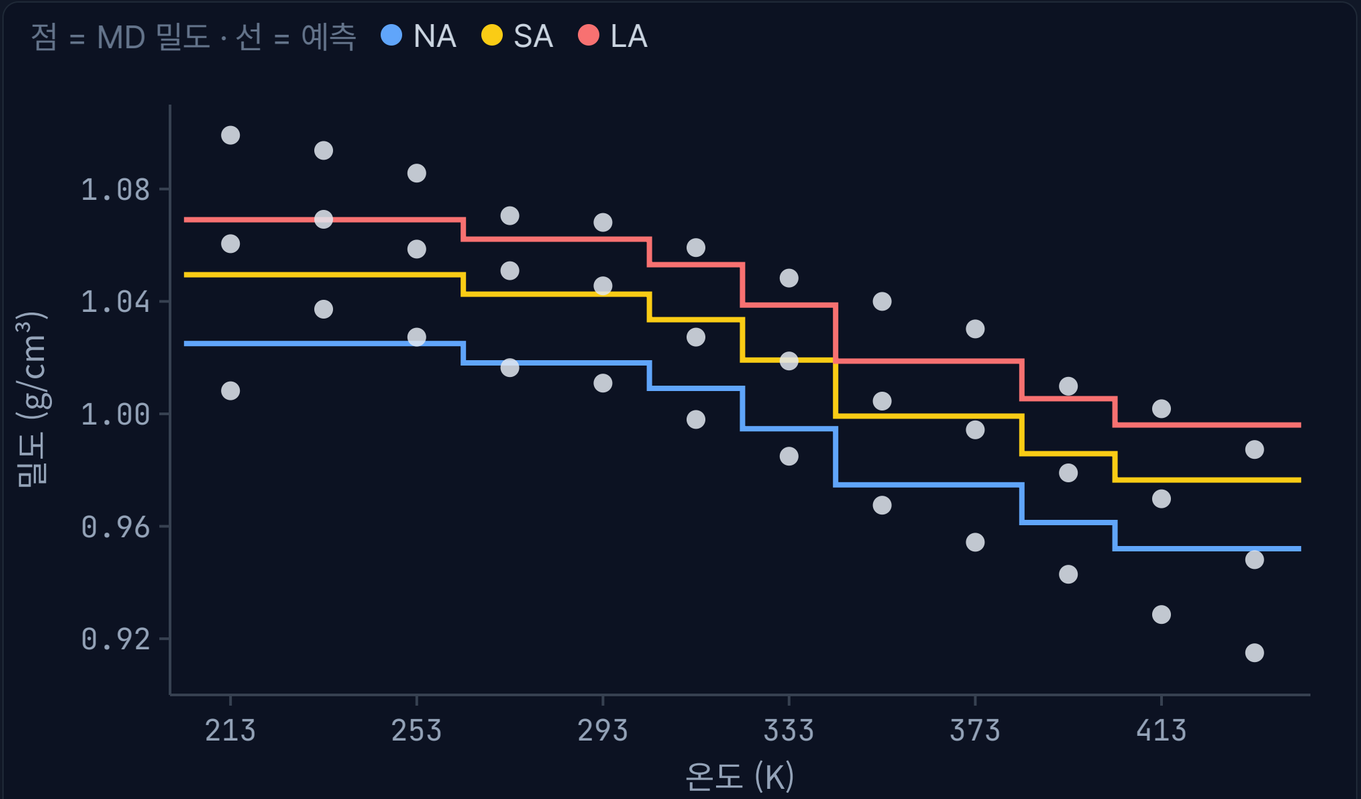
SSE 합 42.84 (분할 전 77.04)
오차 감소 44.4 %
최소 아님 · 「최적 분할」로 확인

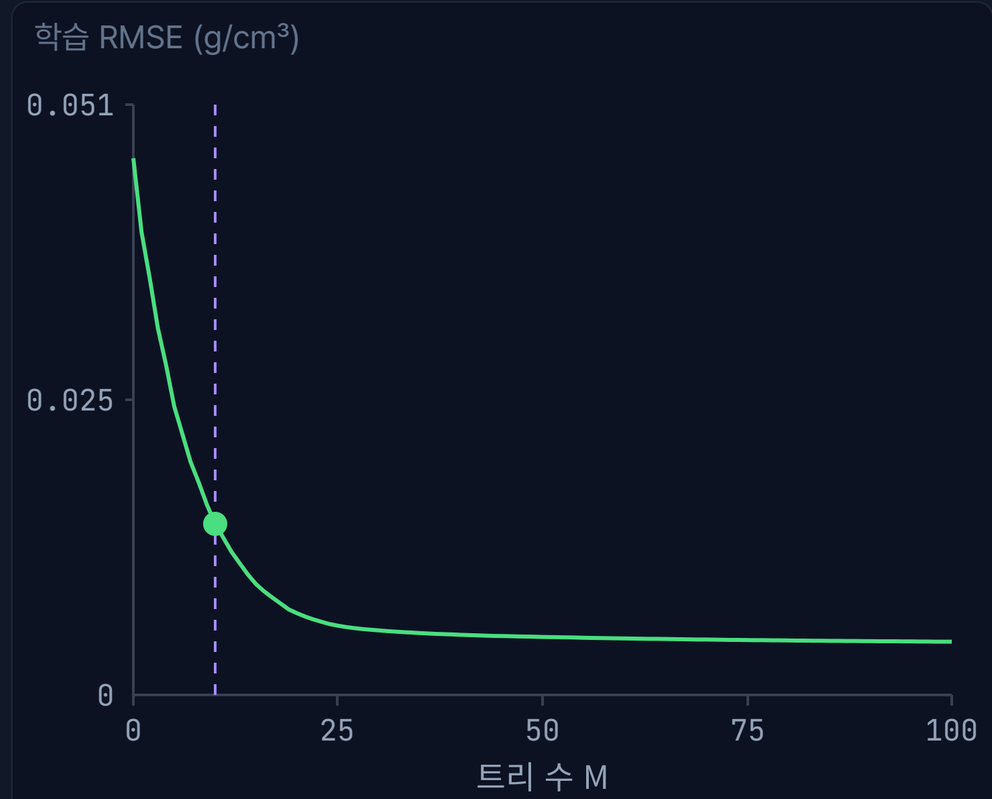
SSE 단위: $(g/cm^3)^2 \times 10^{-3}$ · 트리 학습 = 모든 후보 중 SSE 합 최소 분할 선택 → 잎마다 반복

9-2 · LIVE · BOOSTING

부스팅(boosting): 트리 추가마다 잔차(residual) 감소

+1 트리 | +10 트리 | 초기화 | 학습률 전환 | η = 0.3 | M = 10 | 깊이 1 트리 · 특징: 온도 · 노화





10번째 트리: 온도 ≤ 263 K → 왼쪽 +0.0052 · 오른쪽 -0.0017

학습 RMSE 0.0147 g/cm³ (트리 0개 = 평균 예측 0.0463)

9-2 · SPLIT & FIT

누수 없는 학습 절차

Python

```
from sklearn.model_selection import GroupKFold
import xgboost as xgb

gkf = GroupKFold(n_splits=5)
for tr, va in gkf.split(X, y, groups=comp_id):
    mu, sd = X[tr].mean(axis=0), X[tr].std(axis=0)
    X_tr, X_va = (X[tr]-mu)/sd, (X[va]-mu)/sd
    model = xgb.XGBRegressor(
        n_estimators=800, learning_rate=0.03,
        max_depth=5, subsample=0.8,
        colsample_bytree=0.8, reg_lambda=1.0)
    model.fit(X_tr, y[tr])
    pred = model.predict(X_va)
```

그룹 분할(GroupKFold)

comp_id로 묶어 같은 조성이 학습 · 검증 양쪽에 걸치지 않게 배치

정규화(standardization) 시점

학습 폴드에서 μ · σ 를 구해 검증 폴드에 적용

라벨 변환

점도는 log10 변환 후 학습 · 보고 시 역변환

표본 가중

MD 오차가 큰 라벨에 작은 가중치 부여

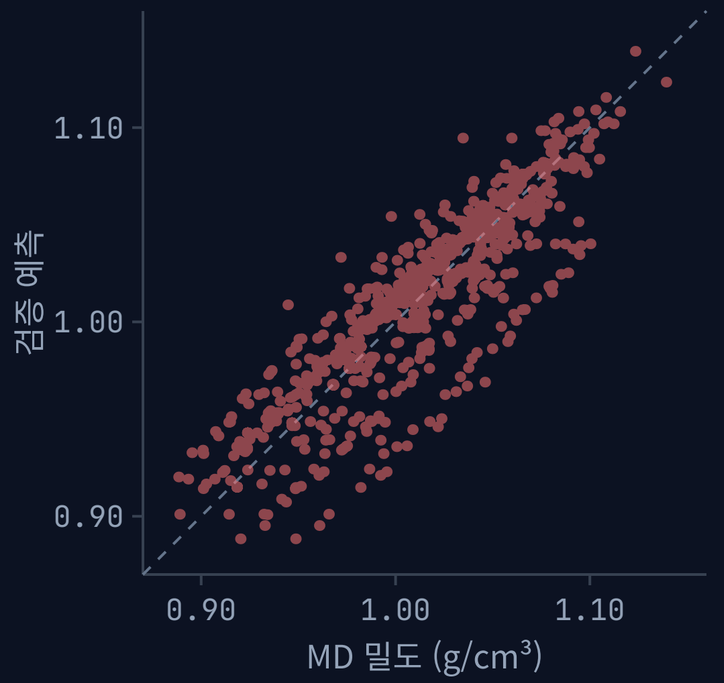
9-2 · LIVE · LEAKAGE

무작위 분할 vs 그룹 분할: 누수(leakage)에 의한 과대평가

모델 전환 | 1-NN (가장 가까운 학습 행 값 그대로 사용) | 재분할 | seed 1

무작위 5-fold

R^2 0.757

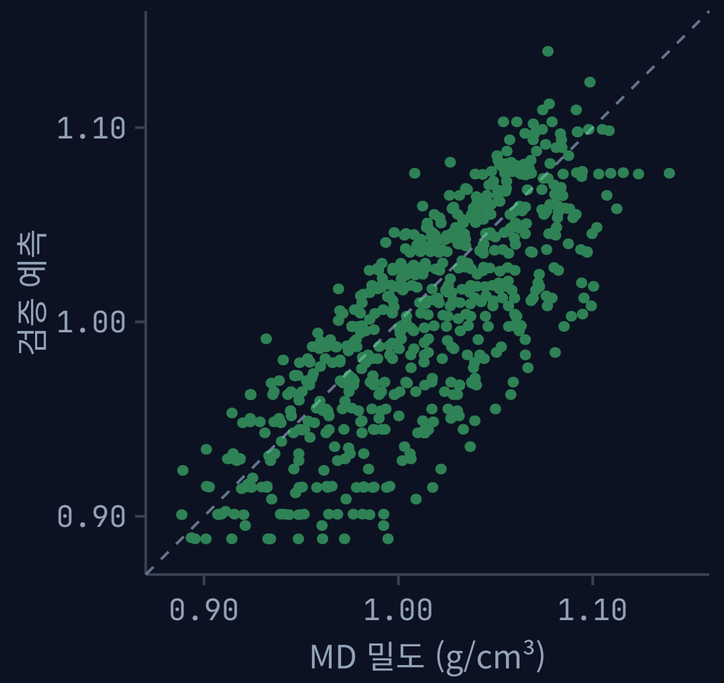


RMSE 0.0244 g/cm³

학습 폴드에 똑같은 행이 있는 검증 행: 56건

그룹 5-fold · 42그룹

R^2 0.434



RMSE 0.0372 g/cm³

학습 폴드에 똑같은 행이 있는 검증 행: 0건

R^2 차이 (무작위 - 그룹) = +0.323

데이터

core672 밀도 670행 · 특징 4개: 온도 · 바인더 · 첨가제 · 노화

무작위 분할

같은 조성의 이웃 온도 · 중복 행이 학습 폴드에 존재 → 기억만으로 정답 근접 · 아래 '똑같은 행' 건수 = 온도 · 조성 · 밀도가 같은 행이 학습 폴드에 있는 검증 행 수(seed마다 변동 · 중복 묶음 58행 기준) ≠ #16의 47행(첫 행 제외 추가 사본 수)

그룹 분할

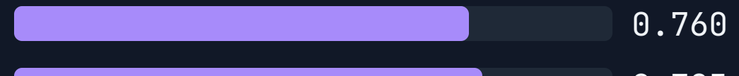
조성 단위로 분리 → 미지 조성 성능의 정직한 추정

수치 = 브라우저 실시간 계산값 (원 보고서 값 아님) · 원천: COMID comid_core672_dataset.csv

9-2 · CIRCULARITY

e_intra 특징 점검: 정보 중복 · 정의상 순환

점검 1 · 파생 가능성 (설계변수 → e_intra 예측 R^2)



→ 정보의 76~95%가 조성 · 산화에 이미 포함

점검 2 · CED 정의상 순환

$$\mathrm{CED} \equiv (\Sigma\, E_{\mathrm{intra}} - E_{\mathrm{total}}) \,/\, V$$

e_intra = CED 정의의 구성요소 → CED 타깃 입력 시 정보 누출 소지 → 제외

물성	T2	T3	ΔR²	판정
밀도	0.881	0.967	+0.085	실이득
CED	0.856	0.944	+0.088	순환 의심
체적탄성률	0.792	0.789	-0.003	무이득
E_inter	0.822	0.857	+0.035	실이득

T2 = 설계변수 + 산화 (MD 불필요) · T3 = T2 + e_intra · group CV R^2

역설계 관점

e_intra = 새 조성의 MD 선행 필요 → 순환 의존 · 기본 구성 = T2 · e_intra는 분자 12종 캐시 재사용 시 밀도 · E_inter에만 선택 적용

출처: COMID comid_feature_redundancy.md (2026-07-03)

9-2 · TUNING

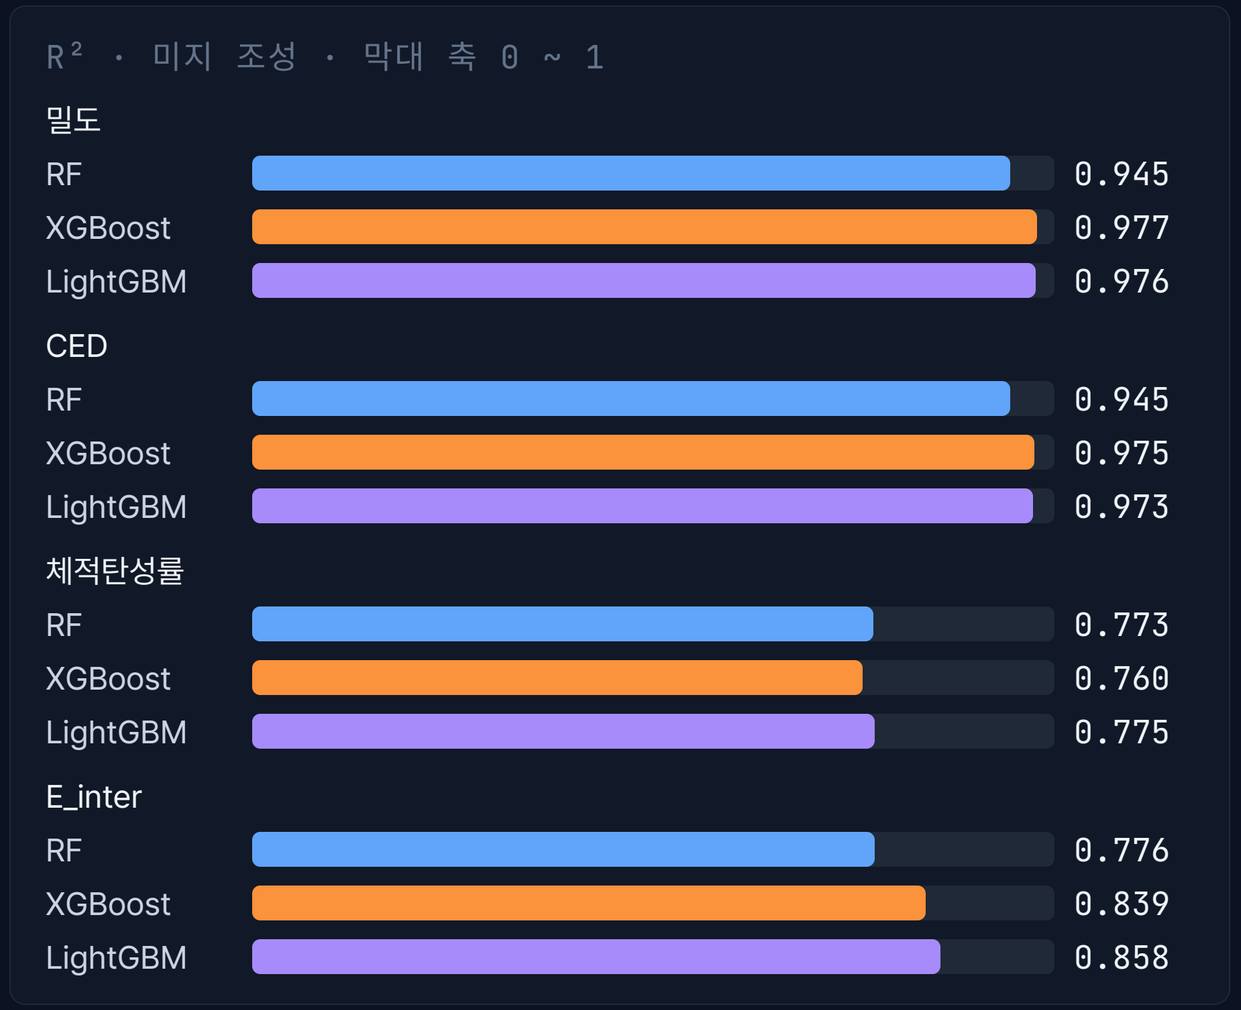
XGBoost 조정 순서

파라미터	권장 범위	역할
learning_rate	0.01 ~ 0.1	작게 설정 후 트리 수 증가 — 안전한 방향
max_depth	3 ~ 7	데이터가 작으면 얕게 — 깊으면 바로 과적합
subsample	0.6 ~ 1.0	행 샘플링으로 분산을 저감
colsample_bytree	0.6 ~ 1.0	상관 높은 표현자 간 영향 분산
reg_lambda	0.5 ~ 10	잎(leaf) 가중치 규제(regularization) — 작은 데이터일수록 크게

과적합 신호 학습 RMSE는 계속 떨어지는데 폴드 간 검증 RMSE 편차가 증가 — 깊이를 줄이고 규제를 증대

9-2 · MODEL COMPARISON

RF · XGBoost · LightGBM 비교: Group 5-fold CV



RMSE	RF	XGB	단위
밀도	0.0116	0.0074	g/cm³
CED	9.65	6.51	MPa
체적탄성률	0.478	0.492	GPa
E_inter	115.4	97.9	kcal/mol

XGBoost 우세

밀도 +0.032 · CED +0.030 · E_inter +0.063 (RF 대비 R^2 · 막대값 차 · 밀도 0.977 − 0.945)

체적탄성률

RF 0.773 vs XGBoost 0.760 — 온도가 거의 전부 설명 → 모델 차이 작음

선형 기준선

1차 모델링(SARA 특징): Ridge가 밀도 · 체적탄성률 · E_inter 최고 → 선형 모델 비교 필수

출처: COMID comid_rf_vs_xgb.csv (RF · XGB) · comid_model_comparison.csv (LightGBM) · n = 612 (CED 613) · comid_modeling_report.md · #24 표와 별도 실행 → 체적탄성률 · E_inter 값 차이

9-2 · FEATURE SETS

특징 세트별 성능: 온도만 → 분자특성 → 첨가제 특성

특징 세트	밀도	CED	체적탄성률	E_inter
온도만	0.603	0.567	0.808	0.382
+ 바인더 분자특성	0.871	0.775	0.799	0.782
+ 첨가제 원핫	0.974	0.971	0.797	0.856
+ 첨가제 분자특성	0.977	0.975	0.784	0.842

체적탄성률
온도만으로 0.808 · 특징 추가 효과 없음 → 온도 지배 물성

E_inter
온도만 0.382 → 바인더 분자특성 추가 0.782 · 분자 크기 효과

첨가제 분자특성
원핫과 성능 동등 (밀도 0.977 vs 0.974) + 새 첨가제 외삽 가능 → 최종 선택

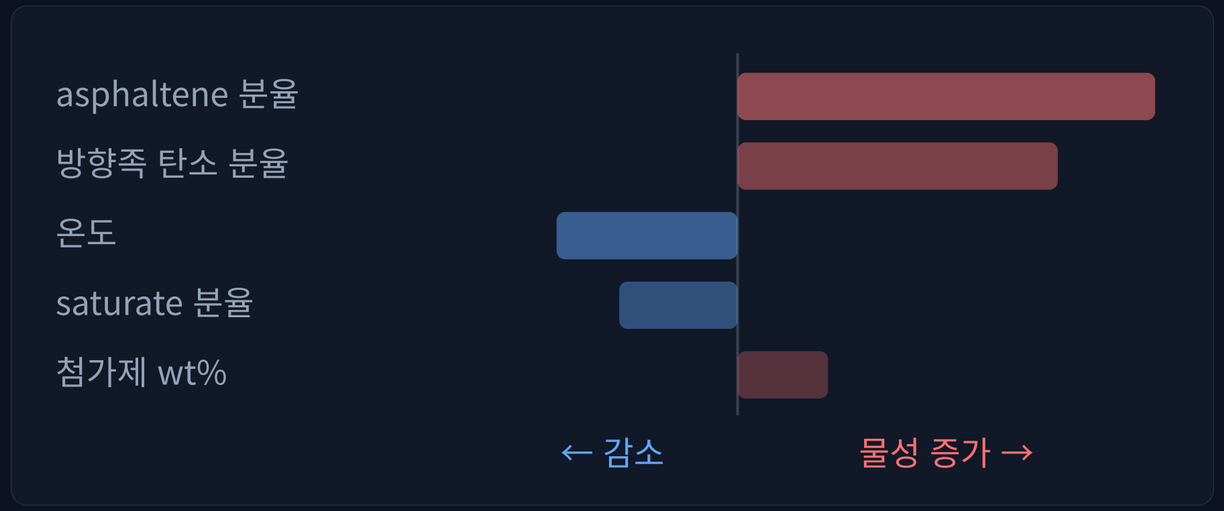
Group CV R^2 · 출처: COMID comid_feature_correction.md (모델 · n 미기재) · #23(comid_rf_vs_xgb.csv · XGBoost · n = 612)과 별도 실행 → 밀도 · CED 같음 · 체적탄성률 0.784 vs 0.760 · E_inter 0.842 vs 0.839 · 첨가제 분자특성 = 문헌 대표값

9-3

SHAP 해석

16분 · SHAP 순위 · 누적 분해 · PDP · 특징 재정련

SHAP 개념: 한 예측을 변수별 기여로 분해



SHAP 값(SHapley Additive exPlanations)
한 예측에서 각 변수의 기여량 · 기준값(평균 예측) + 기여 합 = 예측값

읽는 법
상관이지 인과가 아님 — 물리적 타당성 검토 필수

특징 재정련
기여도 0 근처 변수 제거 · 상호작용이 보이면 새 변수 구성

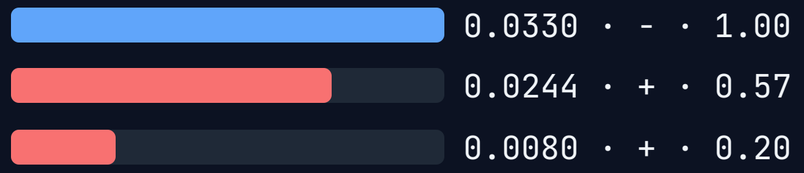
경고
상관 높은 변수끼리 기여도 분할 → 각각 작게 관측

9-3 · SHAP RESULTS

core672 SHAP 순위: 온도 1순위 · 물성별 2순위 상이

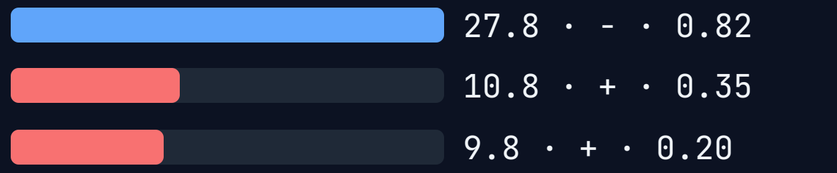
밀도

mean |SHAP| (g/cm³) · 방향 · 단조성



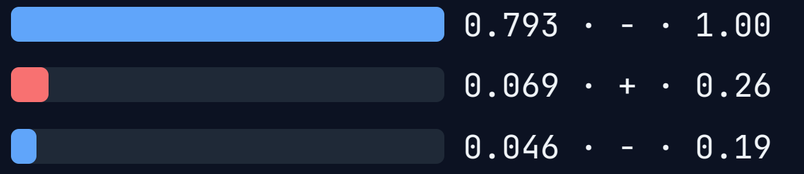
CED

mean |SHAP| (MPa) · 방향 · 단조성



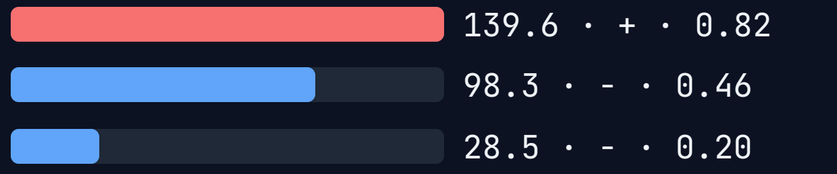
체적탄성률

mean |SHAP| (GPa) · 방향 · 단조성



E_inter

mean |SHAP| (kcal/mol) · 방향 · 단조성



밀도 · CED

2순위 = 바인더 O 분율 (+) → 산화 시 밀도 · 응집 증가

E_inter

2순위 = 바인더 분자 크기 (−) → 큰 분자일수록 더 음의 값 = 강한 상호작용

체적탄성률

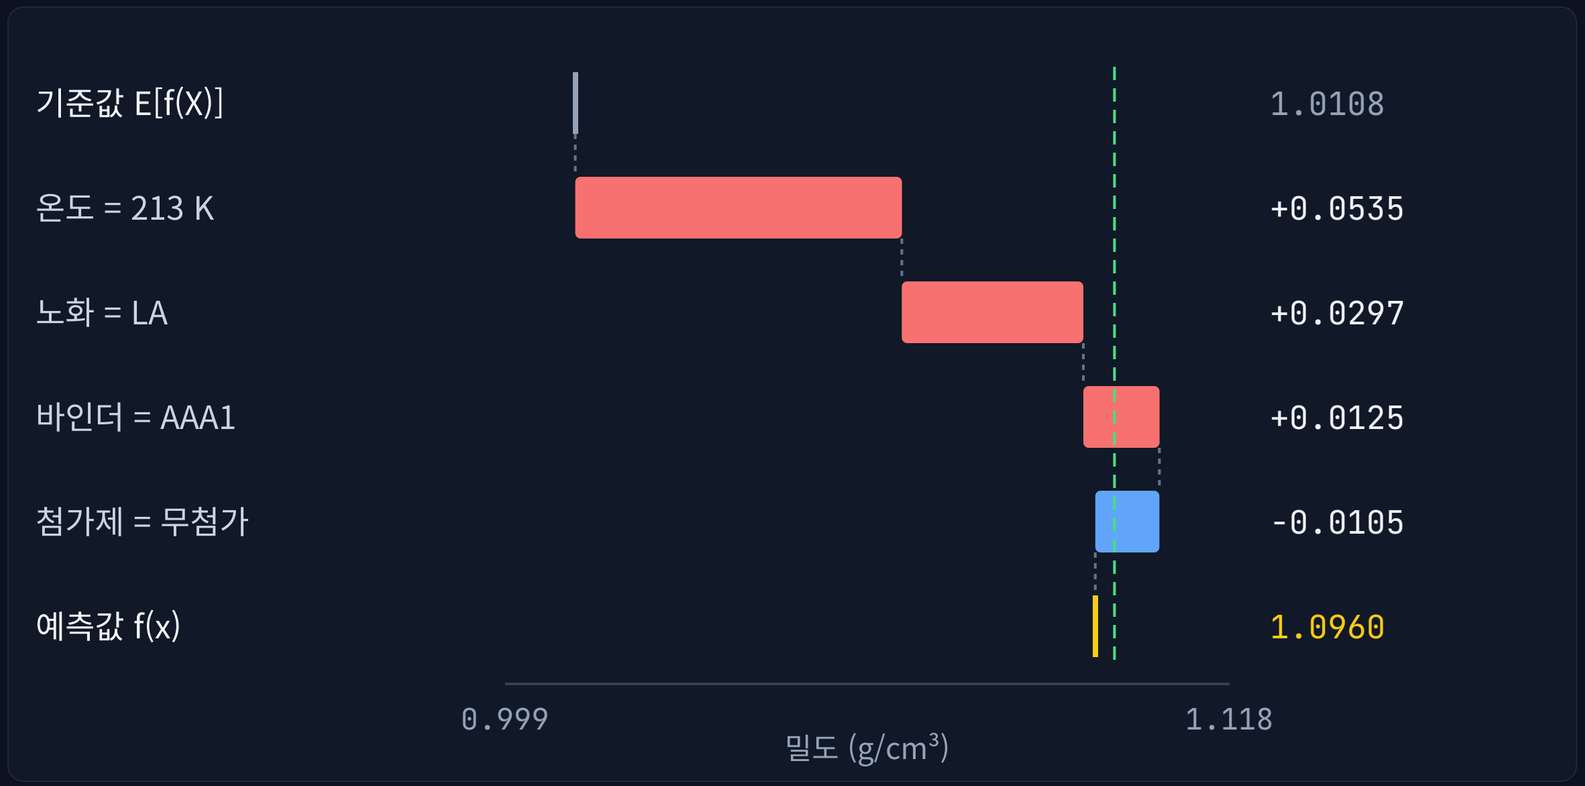
온도 0.79 vs 2순위 0.07 → 사실상 온도만의 함수

모델: LightGBM + TreeSHAP · n = 576 · 빨강 = 증가(+) · 파랑 = 감소(−) · 출처: COMID comid_shap_pdp_quant.csv · comid_shap_pdp_analysis.md

9-3 · LIVE · WATERFALL

SHAP 누적(waterfall): 기준값 + 변수별 기여 = 예측값

◀ 이전 샘플 | 다음 샘플 ▶ | 샘플 1 / 8 · 실험 ID 445 AAA1 · 무첨가 · 장기 노화 LA · 213 K



예측 1.0960 · MD 1.0991 · 오차 −0.0031 g/cm³

가법 모델 → 정확한 SHAP

깊이 1 트리의 합 = 특징별 함수의 합 → $\varphi_j = g_j(x_j) - \text{평균 } g_j$

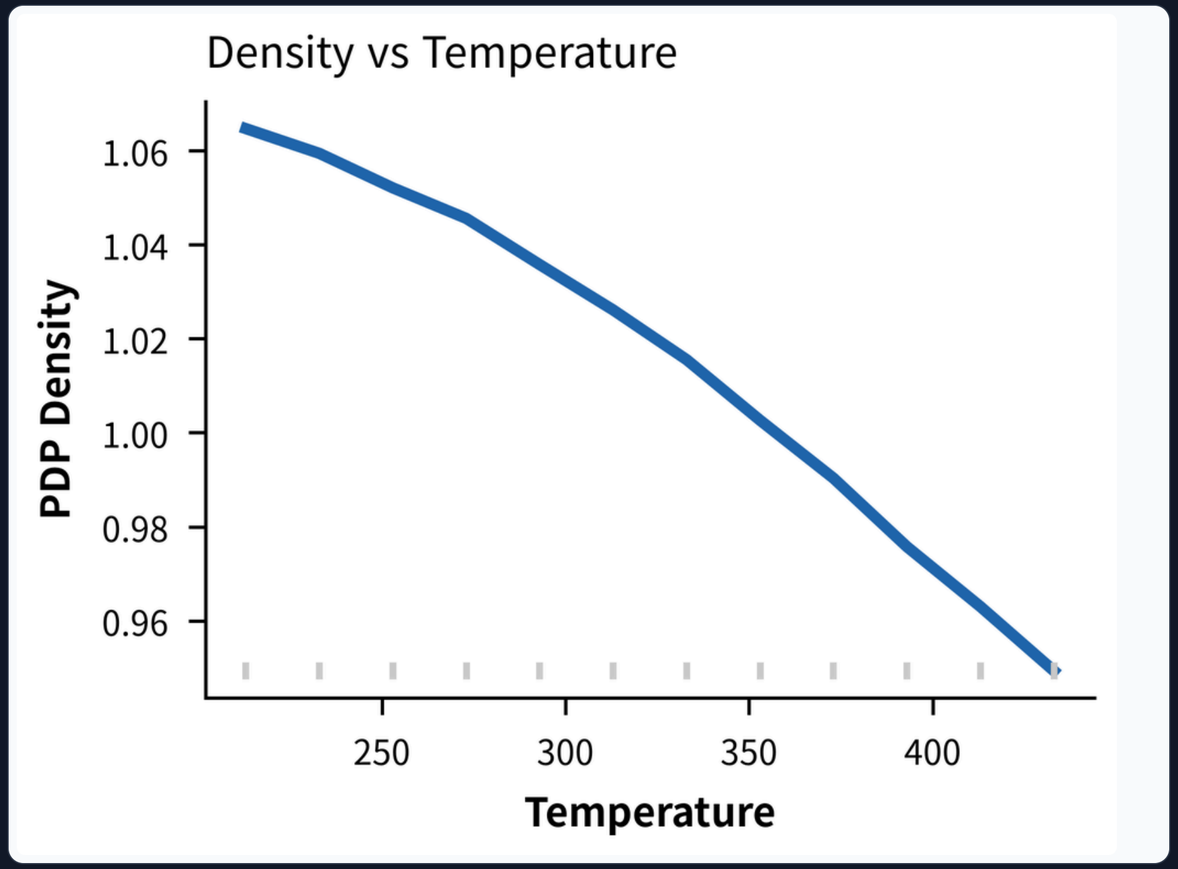
합산 성질

기준값 + Σ φ_j = 예측값 · 막대 순서 = $|\varphi|$ 큰 순

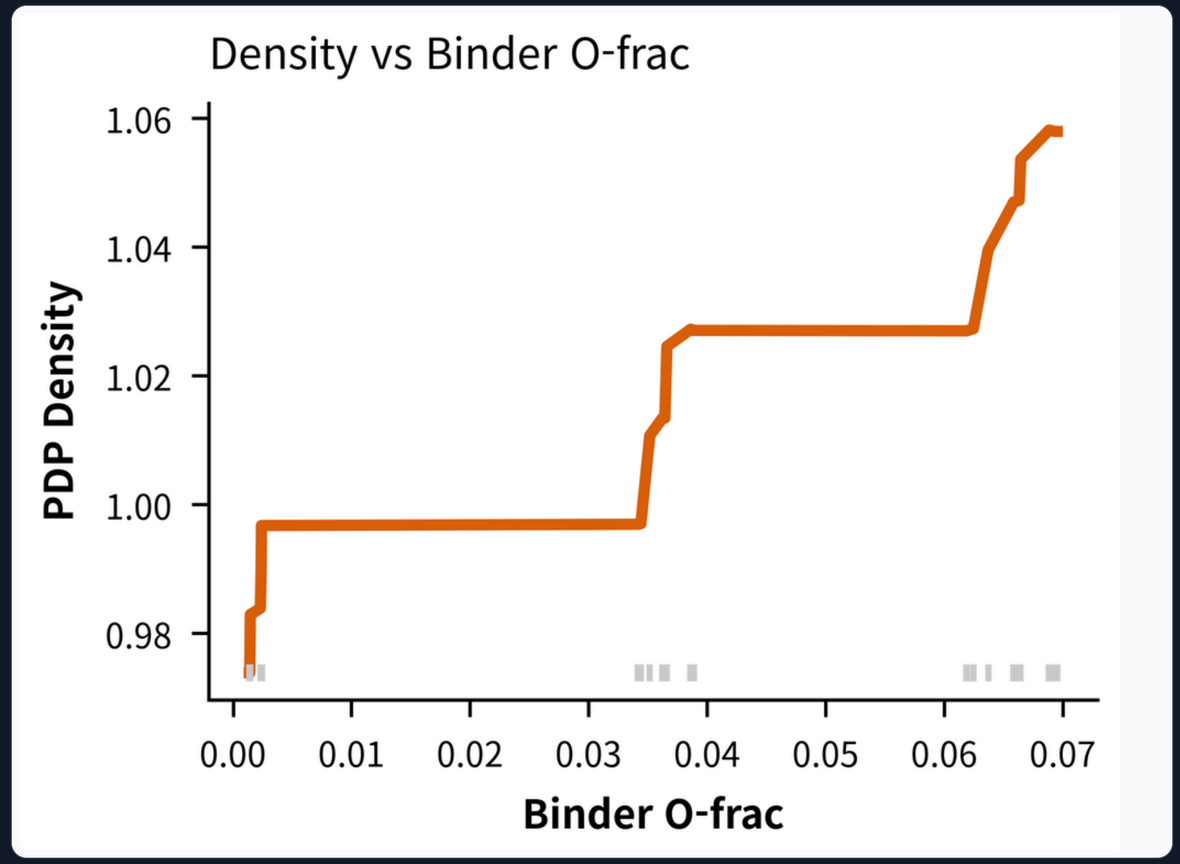
트리 150개 직접 합산 1.0960 = 기준값 + SHAP 합 1.0960

학습: core672 밀도 670행 · 깊이 1 트리 150개 · 수치 = 브라우저 실시간 계산값 (원 보고서 값 아님)

부분의존도(PDP, partial dependence plot): 변수별 함수 형태



밀도–온도: 단조 감소 · 단조성 1.00 · 변화폭 0.115 g/cm³ → 열팽창과 일치

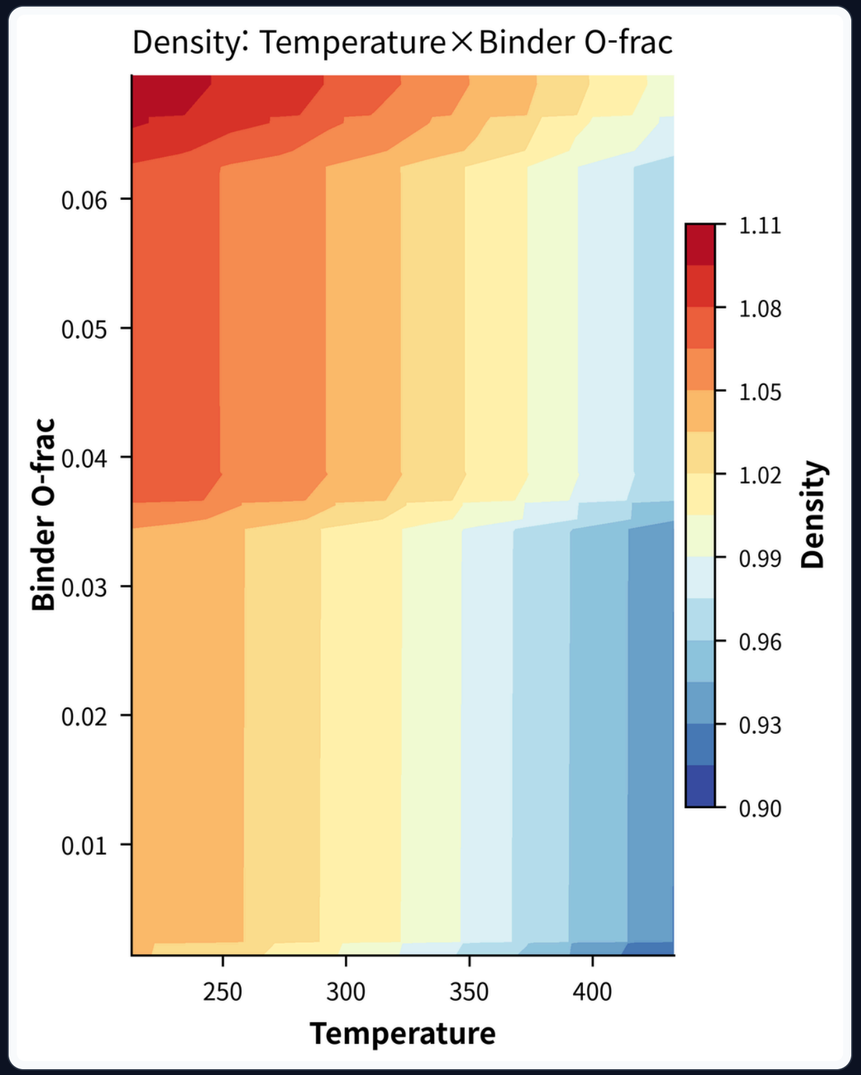


밀도–O 분율: 계단형 증가 · 변화폭 0.084 g/cm³ · 데이터 세 무리(노화 단계)에 집중

읽는 법 그림 아래 회색 눈금 = 실제 데이터 위치 · 눈금 없는 구간의 곡선 = 외삽 → 역설계 목표 구간은 데이터 범위 안으로 제한

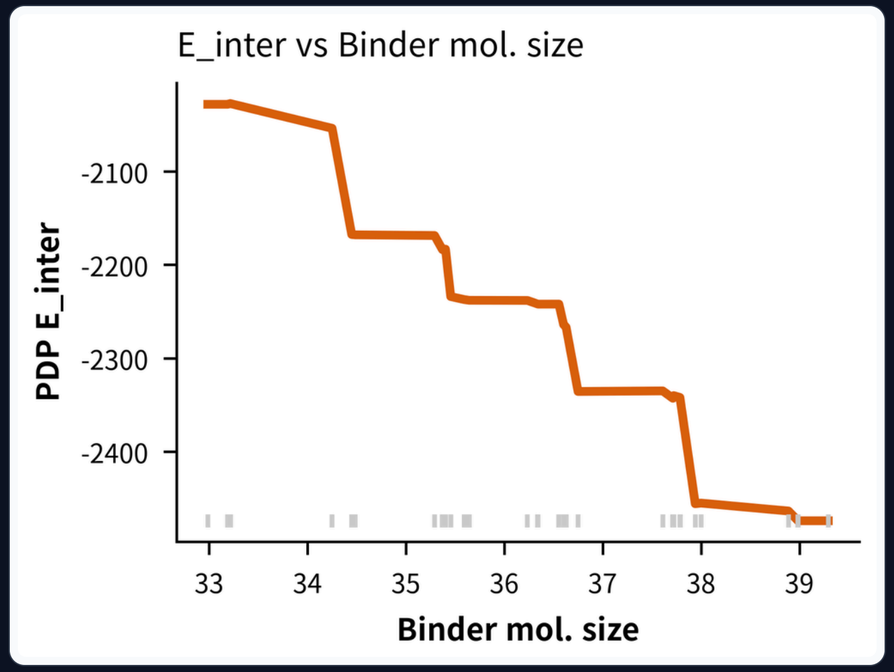
그림: COMID fig_shap_pdp (LightGBM · n = 576) · 변화폭 · 단조성 = comid_shap_pdp_quant.csv

2D PDP: 온도 × O 분율 상호작용 확인



밀도: 온도 × O 분율

등고선 = 거의 세로 띠 → 온도 효과 지배 · O 분율 0.035 부근 계단은 모든 온도에서 같은 방향 → 가산 관계 · 상호작용 약함 (그림 판독)



E_inter: 분자 크기

계단형 감소 · 산점도 회귀 기울기 −85 kcal/mol per atom (MD 계산값) → 큰 분자 = 강한 상호작용

9-3 · REFINEMENT

물리 타당성 점검 → 특징 재정련 5단계

관계	모델 (PDP)	물리 해석	판정
밀도 – 온도	감소 · 단조성 1.00	열팽창	일치
밀도 – O 분율	증가 (+)	산소 도입 → 밀도 상승	일치
CED – 온도	감소 · 단조성 0.82	고온 → 응집 약화	일치
E_inter – 분자 크기	감소 (-)	큰 분자 → 강한 분자간 상호작용	일치
체적탄성률 – 온도	감소 · 단조성 1.00	고온 → 강성 저하	일치

어긋날 때

물리와 반대 방향 → 데이터 오염(예: CED 음수값) · 누수 먼저 점검

01 기여도 ≈ 0 변수 확인
SARA 4종 → 제거

02 다른 특징으로 예측되는 변수 확인
additive_wt (R^2 0.9996) → 제거

03 상관 매우 높은 쌍 확인
r 0.96 · 0.98 → 1개만 유지

04 타깃 정의에 포함된 입력 확인
CED ↔ e_intra → 해당 타깃에서 제외

05 라벨 · 원핫을 물리 수치로 대체
노화 → 산화지수 · 첨가제 → 분자특성

출처: COMID comid_shap_pdp_quant.csv · comid_shap_pdp_analysis.md · comid_feature_correction.md · comid_feature_redundancy.md

PRACTICE

실습 · XGBoost 대리모델과 SHAP

PRACTICE

01 RDKit으로 표현자 계산 · 조성 가중 평균 구성

02 GroupKFold로 밀도 · CED · 점도 모델 학습

03 선형 회귀 기준선과 성능 비교

04 SHAP 요약 그림 작성 · 물리적 해석 한 문단 기재

DELIVERABLE

물성별 RMSE · MAE · R^2 표 (폴드 평균 ± 편차)

SHAP 요약 그림과 해석 메모 · 재정련한 특징 목록

이 성능 = 10주차 GNN의 기준선 · 데이터: comid_core672_dataset.csv (672행) · 주의: 점도 58행 = AAA1 무첨가 NA · SA · LA 3개 그룹뿐 → 5-fold GroupKFold 불가 · 그룹 1개씩 3-fold로 축소 · 폴드 간 편차 큼

퀴즈 9주차

SUMMARY

9주차 정리

01 표현자: 분자 수준 계산 → feature library 관리 → 조성 가중 평균으로 혼합물 표현

02 작은 표 형태 데이터에서 트리 모델 우세 · GNN의 기준선 역할

03 그룹 분할 = 미지 조성 성능의 정직한 추정 · 무작위 분할은 중복 행 누수로 과대평가 가능

04 SHAP · PDP = 예측 설명 + 특징 재정련의 첫 단계 — 물리 타당성 점검 · 인과로 해석 금지

퀴즈 9주차

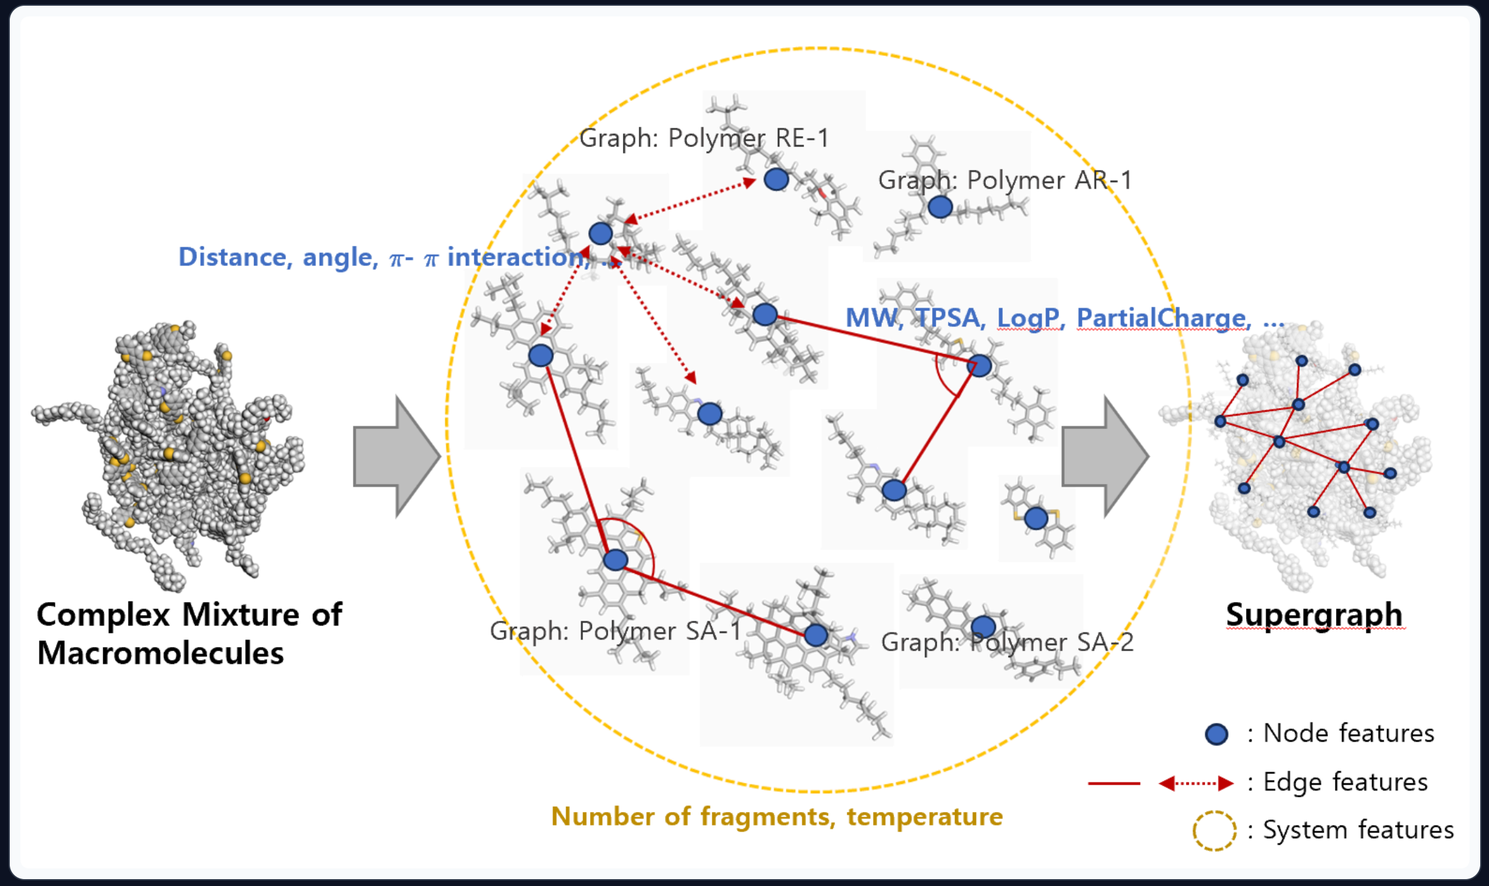
다음 주차 — 기계학습 (2): 그래프 신경망과 능동학습

APPX

부록 · 참고 자료

사례 · Graphormer3D 수퍼그래프 5장 (10주차 그래프 신경망 연계)

수퍼그래프(supergraph) — 분자 1개 = 노드 1개



원자 그래프의 한계

바인더 = 분자량 400 이상 거대분자 60종 이상의 혼합물 — 원자 전체를 노드로 두면 비결합 상호작용까지 명시 → 계산량 급증

수퍼그래프 표현

거대분자 하나 = 부분그래프(subgraph) = 노드 하나 · 분자 사이 비결합 상호작용 = 엣지 · 셀 전체 = 수퍼그래프

장점

3차원 배치 정보 유지 · 원자 단위 상호작용 전체를 모델링하지 않아 비용 대폭 감소 · 첨가제–바인더 상호작용 표현 유지

중요도가 커지는 부분

노드 · 엣지에 담을 정보 — 표현자 선택 = 모델 성능 결정 요인

다계층 특징 — 노드 · 엣지 · 시스템

노드 10개 · 분자 자체의 성질 (RDKit)

MolWt · TPSA · MolLogP · 수소결합 주고받음 · 부분전하 · 헤테로원자 수 · 회전가능 결합 수 · FractionCSP3 · 지방족 고리 수 · 방향족 고리 수

엣지 6개 · 분자쌍 사이 (15 Å 컷오프)

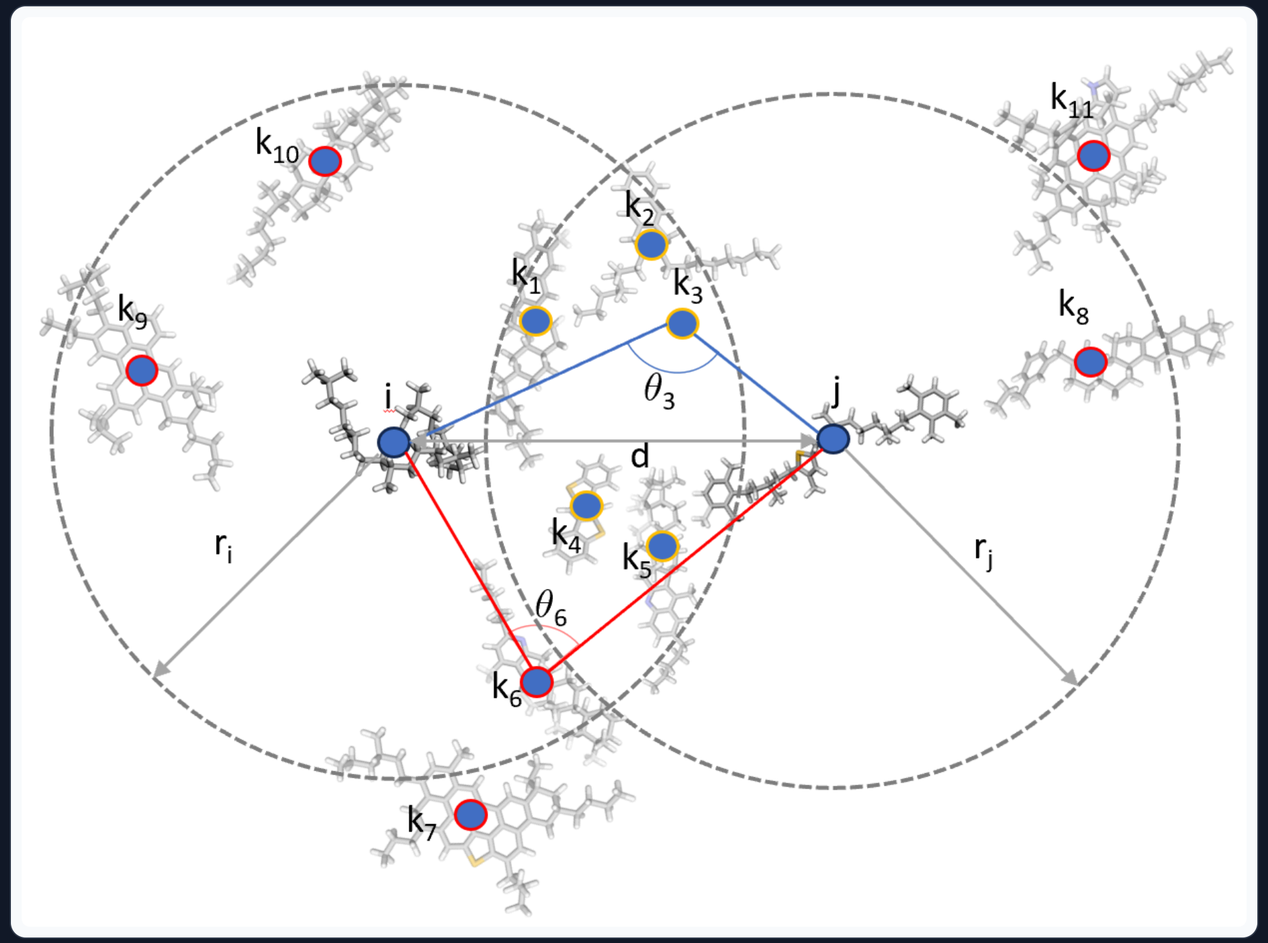
분자간 거리 · 평균 각도 · 수소결합 잠재력 · π–π 상호작용 잠재력 · LogP 차이 · 지문(fingerprint) Tanimoto 유사도

시스템 2개 · 셀 전체 조건

NumFragments(분자 수) · 온도 — 뒤의 ablation에서 영향 최대로 확인

설계 관점의 의미

유연성(회전 결합) · 극성(TPSA · LogP) · 상호작용 유형(수소결합 · π–π) = 첨가제의 패킹 · 혼화성 · 부착과 직접 연관

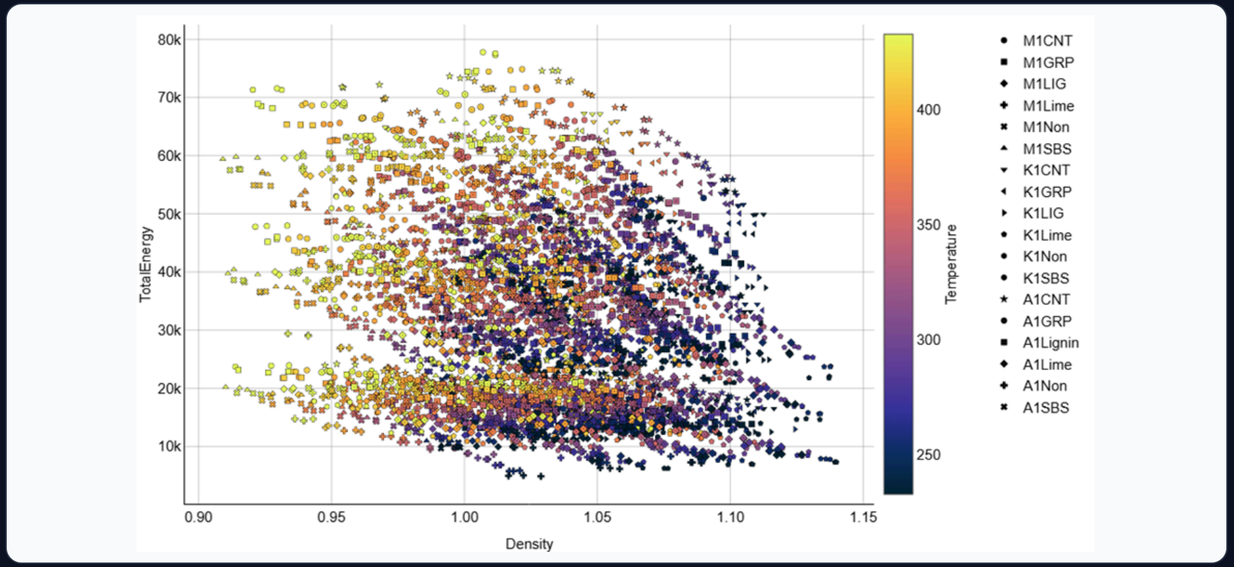


평균 각도: 노드 i · j의 반경이 겹치는 영역의 제3 노드(파란 테두리)로만 계산 — 겹침 밖 노드(빨간 테두리) 제외 → 국소 배치만 반영

APPENDIX · DATASET 3/5

5,346 케이스 — MD 분산을 학습 데이터에 포함

축	수준	내용
바인더	3	AAA1 · AAK1 · AAM1 (12 대표분자 조성비)
노화	3	NA · SA · LA — 말단에 산소 도입
첨가제	6	무첨가 · SBS · CNT · GRP · LIG · SiO_2
셀 크기	3	X1 · X2 · X3 — 조성비 같고 분자 수만 배수
무작위 실현	3	R1 · R2 · R3 — 같은 조성의 다른 초기 배치
온도	11	233~433 K · 20 K 간격 · NPT 1 ns · Δt 1 fs

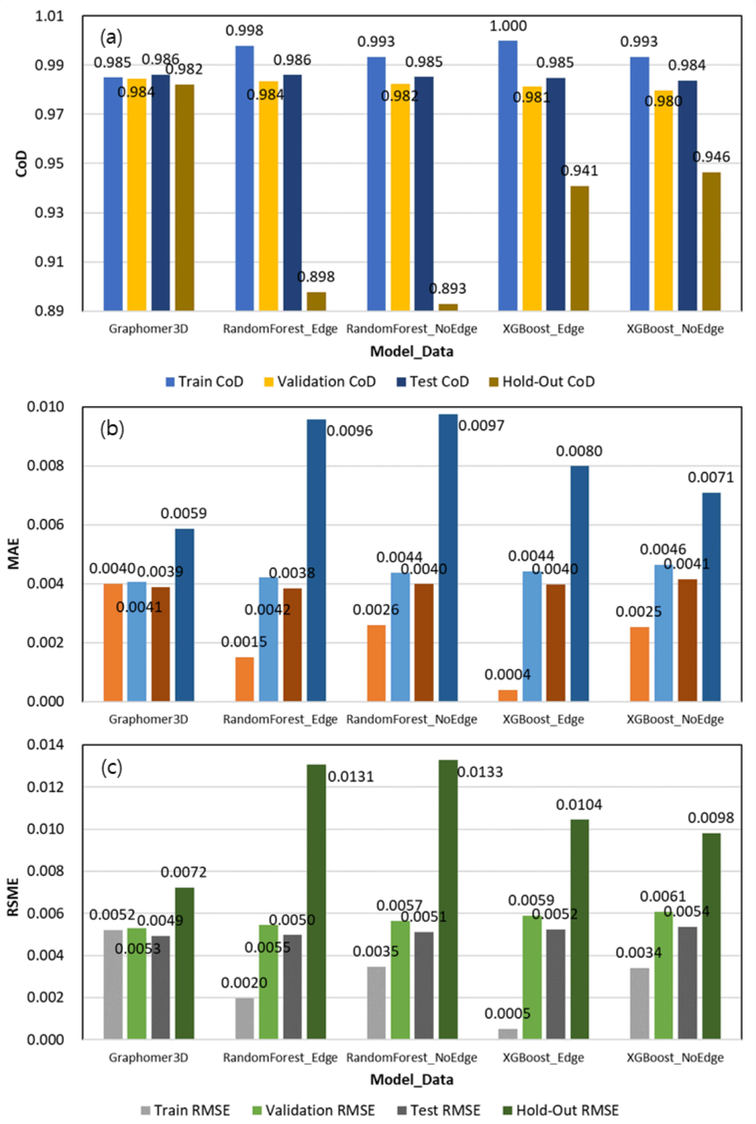


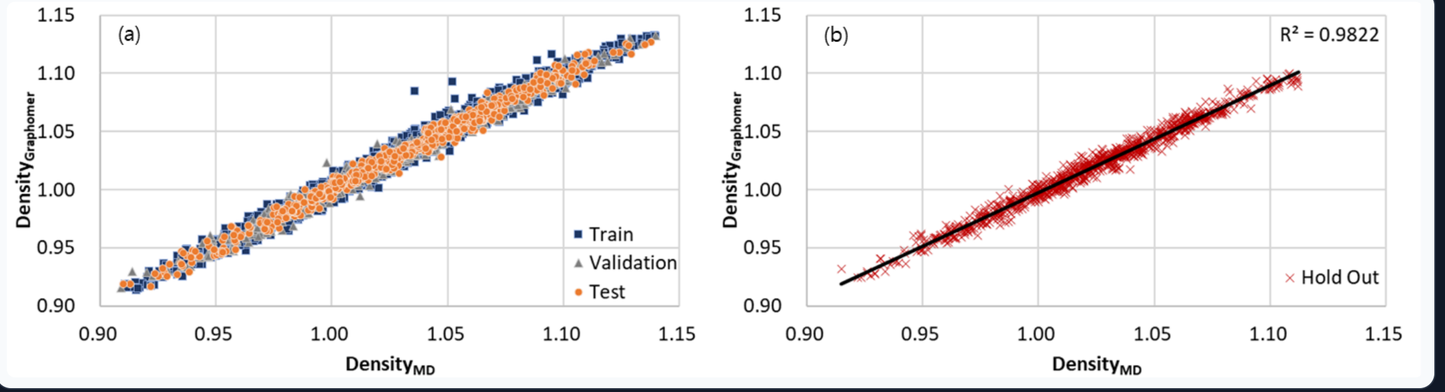
세로축 TotalEnergy · 가로축 밀도 · 범례의 Lime = 원 그림 표기 그대로 · 논문 본문 · 표의 첨가제는 SiO_2 (범례 표기 불일치)

설계 요점

셀 크기 · 초기 배치를 축으로 넣어 MD 분산 자체를 학습 데이터에 포함 · 그래핀 첨가 891건은 일반화 시험용 hold-out 으로 완전히 분리

예측 결과 — 모델 간 차이는 hold-out에서 발생





밀도 · hold-out R^2

SG-Graphormer3D 0.982
XGBoost(엣지) 0.941 · RF(엣지) 0.898

학습 성능은 표 모델 우세

Train R^2은 RF · XGB가 0.998~1.000 — 처음 보는 첨가제(그래핀)에서 성능 급락 = 차이의 원인

총에너지(TotalEnergy)는 양상 상이

조성이 거의 결정 → XGBoost hold-out R^2 0.993 — 합 · 평균 같은 통계 기술자만으로 충분 · 그림 축 = TotalEnergy(계 총에너지) · CED(응집에너지밀도)와 다른 양 · 논문 절 제목의 'CED'는 본문 · 그림상 총에너지

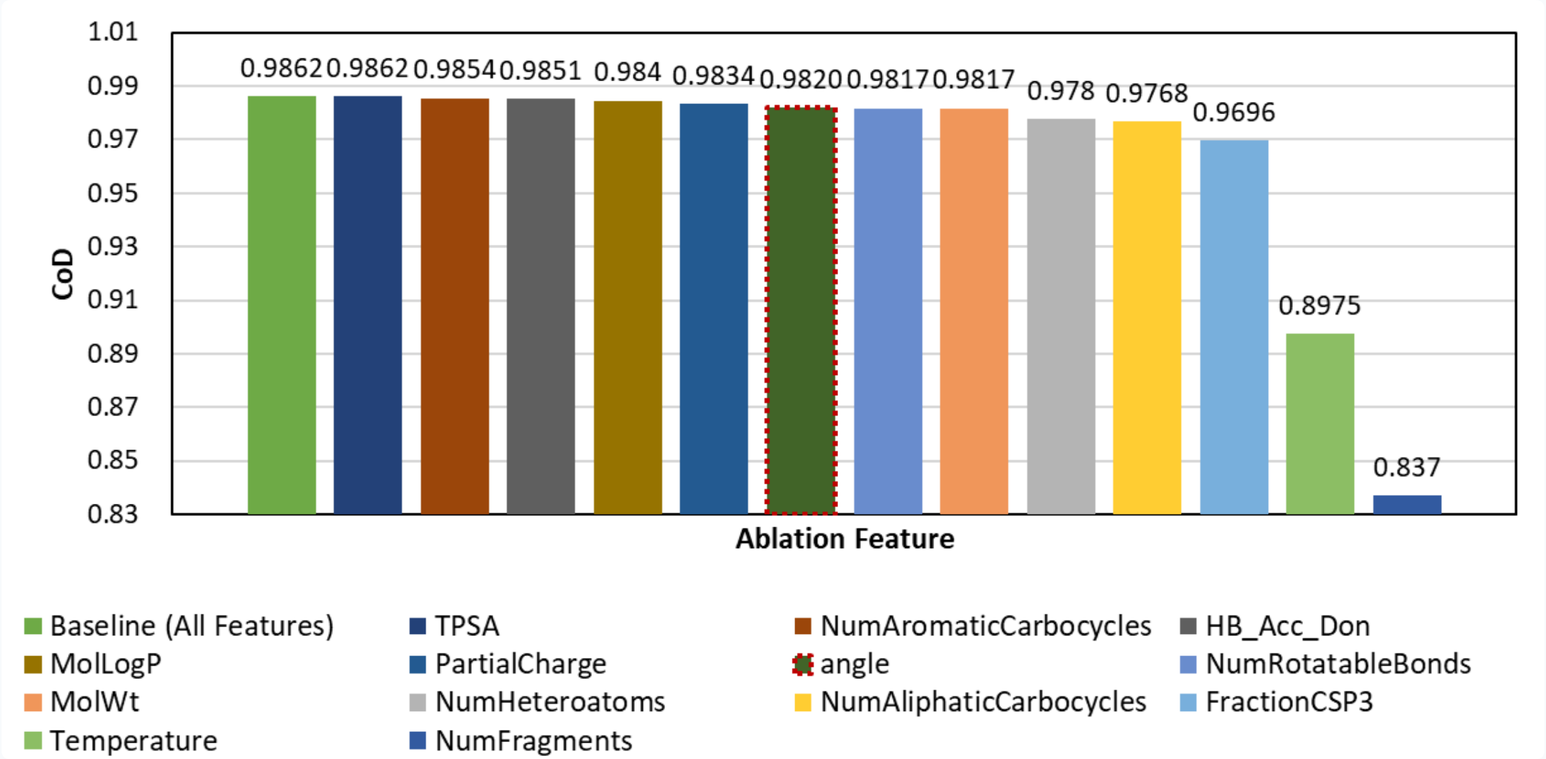
읽는 법

밀도는 3차원 패킹이 지배 → 위치 정보를 담는 그래프가 필요 · 에너지는 조성이 지배 → 빠른 표 모델로 충분

APPENDIX · ABLATION STUDY 5/5

제거 실험(ablation) — 특징 1개씩 제거 후 기여도 판독

방법 기준선(모든 특징 포함)과 같은 학습 · 검증 · 시험 절차 유지 · 특징 하나만 제거 후 재학습 · 성능 하락 시에만 중요도 근거로 판독 · 제거 후 향상된 결과는 상호보완 효과 가능성 → 과해석 금지



시스템 특징이 지배

NumFragments 제거 0.837 · 온도 제거 0.898 (기준선 0.986) — 온도: 부피 팽창 · 분자 수: 질량 · 부피 모두에 영향(투입량 반영)

노드 특징의 기여

FractionCSP3 0.970 · 지방족 고리 수 0.977 · 헤테로 원자 수 0.978 — 유연성 · 입체 부피 · 극성 → 패킹 효율

엣지 특징 · 각도

각도 제거 0.982 — 작지만 유의미 · 국소 기하 배치의 밀도 관여 근거