COMID

WEEK 10 · 차시 10-1 ~ 10-4 · 50분

기계학습 (2) GNN과 능동학습

분자 그래프와 message passing · 등변 GNN과 Graphormer-3D · MD 데이터 학습 · 불확실성과 능동학습

윤태영 (Taeyoung Yun)

실습 · PyTorch Geometric 회귀

퀴즈 10주차

RECAP · WEEK 09

지난 주차 요약과 이번 주차의 위치

9주차 산출물

특징 · 라벨 · 폴드가 정리된 학습용 데이터셋

손으로 만든 특징의 한계

새 골격(scaffold)의 분자마다 특징 재정의

이번 주차

구조에서 표현을 직접 학습하는 그래프 신경망(GNN, graph neural network) 사용

파이프라인 6단계 중 04 대리모델(surrogate model) 학습 · 05 능동학습(active learning)에 해당

OBJECTIVE

10주차 학습목표

01 분자 · 결정을 그래프로 표현하고 메시지 패싱(message passing) 한 층의 계산을 식으로 설명

02 불변(invariance) · 등변(equivariance)의 뜻과 Graphormer-3D가 3D 거리를 넣는 방식을 설명

03 MD 결과로 학습 데이터를 구성하고 풀링(pooling) · 학습 루프 · 소재 홀드아웃(hold-out)으로 검증

04 예측 불확실성의 보정(calibration)을 확인하고 획득함수(acquisition function)로 다음 MD 계산을 선택

AGENDA

10주차 구성

10-1	분자 그래프와 message passing	12분
10-2	등변 GNN과 Graphormer-3D	16분
10-3	MD 데이터 학습	10분
10-4	불확실성과 능동학습	12분

10-1

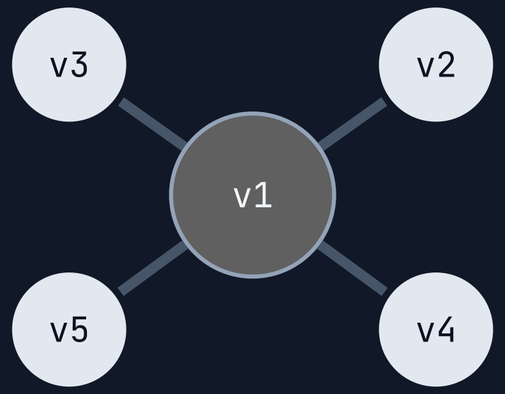
분자 그래프와 message passing

12분 · 분자 · 결정의 그래프 표현 · 이웃 정보 집계

10-1 · GRAPH

분자를 그래프로 기재

예: 메탄 CH_4 · v1 = C · v2–v5 = H



노드(node) = 원자 · 엣지(edge) = 결합

노드 특징 x_v

원소 one-hot · 혼성(hybridization, sp/sp^2/sp^3) · 형식전하(formal charge) · 고리 포함 여부 · 수소 개수 · 부분전하

엣지 특징 e_{uv}

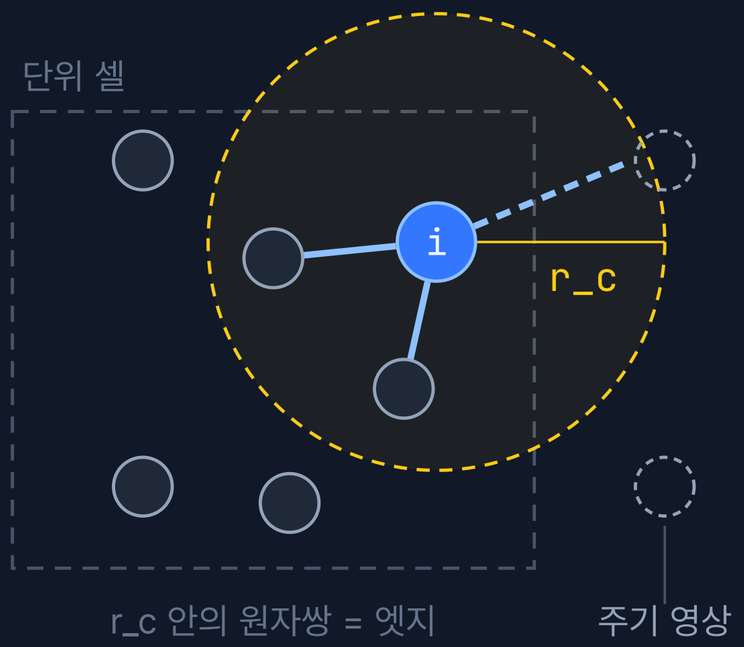
결합 차수 · 방향족 여부 · 고리 내부 여부 · (선택) 결합 길이

왜 그래프인가

원자 번호 순서를 바꿔도 같은 분자로 인식 — 순열 불변성(permutation invariance)이 구조상 자동 보장

10-1 · CRYSTAL GRAPH

결정·벌크 셀: 결합 대신 거리 기준 엣지



엣지 규칙

컷오프 반경 r_c 안의 모든 원자쌍 연결 — 셀 경계를 넘으면 주기 영상(periodic image)과 연결 (2주차 주기경계조건)

엣지 특징

결합 차수 대신 거리 d_{ij} 사용 — 가우스 기저(Gaussian basis)로 전개한 벡터로 상호작용 세기를 연속적으로 표현

분자 단위 노드

바인더처럼 거대분자 혼합물은 분자 하나를 노드로 설정 — 9주차 수퍼그래프(supergraph) 사례 · 분자쌍 15 Å 컷오프

주의

셀 한 변이 $2r_c$보다 짧으면 한 원자쌍이 여러 영상으로 중복 연결 — 엣지 생성 코드의 처리 여부 확인

10-1 · MESSAGE PASSING

메시지 패싱 한 층의 계산

$$m_v^{(l)} = \sum_{u \in N(v)} M(h_u^{(l)}, e_{uv}) \quad \cdot \quad h_v^{(l+1)} = U(h_v^{(l)}, m_v^{(l)})$$

M = 메시지 함수 · U = 갱신 함수 · N(v) = v의 이웃 원자 집합



L층 = L결합 떨어진 원자까지 정보가 도달

보통 L = 3 ~ 5

대표 구조

GCN(graph convolutional network) · GIN(graph isomorphism network) · MPNN(message passing neural network) · GAT(graph attention network) — 메시지 · 갱신 함수의 선택 차이

층이 너무 많으면

모든 노드 표현이 비슷해지는 과평활(over-smoothing) — 잔차 연결(residual connection)로 완화

엣지 활용

방향족 · 결합 차수를 메시지에 포함해야 고리 구조 구분 가능

10-1 · CHECK

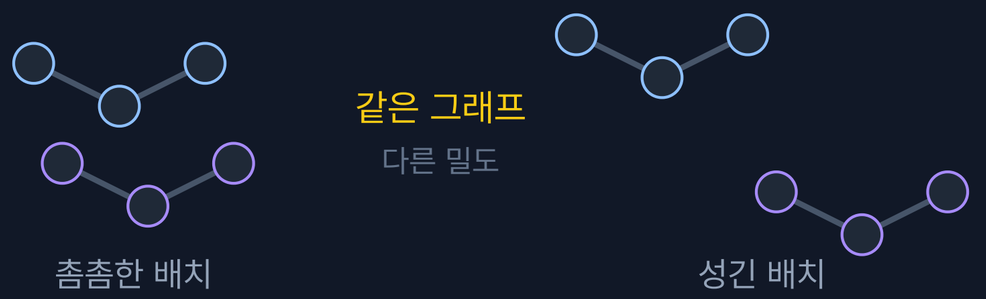
위상 그래프만으로는 3차원 배치 구분 불가

확인 질문

01 원자 번호를 바꿔 입력해도 예측이 같은 이유는?

02 메시지 패싱이 3층일 때 한 원자가 반영하는 결합 거리는?

03 벤젠과 사이클로헥세인 구분에 필요한 노드 · 엣지 특징은?



남는 한계

결합 위상에는 분자 사이 거리와 입체 배치 정보 없음 — 밀도처럼 패킹이 결정하는 물성은 좌표 필수

10-2로 좌표를 입력에 포함 · 구조를 회전 · 이동해도 스칼라 출력(밀도)은 같은 답 = 불변성(invariance) · 벡터 · 힘 출력은 함께 회전 = 등변성(equivariance)

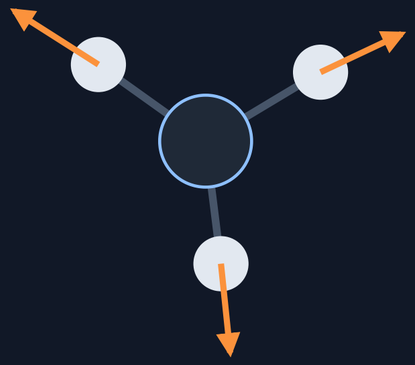
10-2

등변 GNN과 Graphormer-3D

16분 · 대칭을 보존하는 3D 좌표 사용법

10-2 · SYMMETRY

좌표 사용의 전제 — 회전 · 이동 대칭 조건

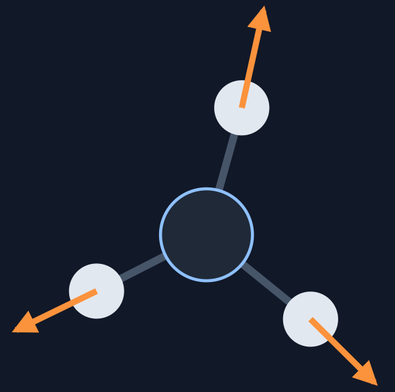


원래 좌표 x

회전 R · 이동 t

에너지 E · 밀도 → 그대로

힘 F (주황 화살표) → 함께 회전



돌린 좌표 Rx + t

불변 · invariance

$$\mathrm{f}(Rx + t) = \mathrm{f}(x)$$

스칼라 출력 — 밀도 · CED(cohesive energy density) · 에너지는 좌표 회전 후에도 같은 값

등변 · equivariance

$$\mathrm{f}(Rx + t) = R\,\mathrm{f}(x)$$

벡터 출력 — 힘 · 쌍극자는 좌표와 함께 회전 · ML 힘장의 조건

좌표를 그대로 넣으면 같은 구조를 회전한 입력마다 다른 답 — 회전 증강(augmentation)으로 근사 가능하나 필요 데이터 대폭 증가

10-2 · EQUIVARIANT GNN

대칭 보존의 두 가지 설계

A · 불변 특징만 사용

$$\mathrm{m}_{ij} = \varphi(h_i, h_j, d_{ij}, \theta_{ijk})$$

입력	원자 간 거리 d_{ij} · 결합각 θ_{ijk} — 회전해도 변하지 않는 양
대표	SchNet (거리) · DimeNet (거리 + 각도) · Graphormer-3D
출력	스칼라 물성에 적합 — 힘 = 에너지 미분 F = −∇E
비용	낮음 — 층마다 스칼라 특징만 갱신

B · 벡터도 함께 전달

$$x_i' = x_i + C \sum_j (x_i - x_j)\, \varphi_x(\mathrm{m}_{ij})$$

입력	좌표 · 벡터 특징을 층마다 갱신 — 상대 벡터만 쓰므로 등변
대표	EGNN(E(n)-equivariant GNN, 위 식) · PaiNN · NequIP
출력	힘 · 쌍극자를 직접 등변으로 — ML 힘장(MLIP, machine-learned interatomic potential)의 주류
비용	높음 — 벡터 · 텐서 특징을 층마다 함께 연산

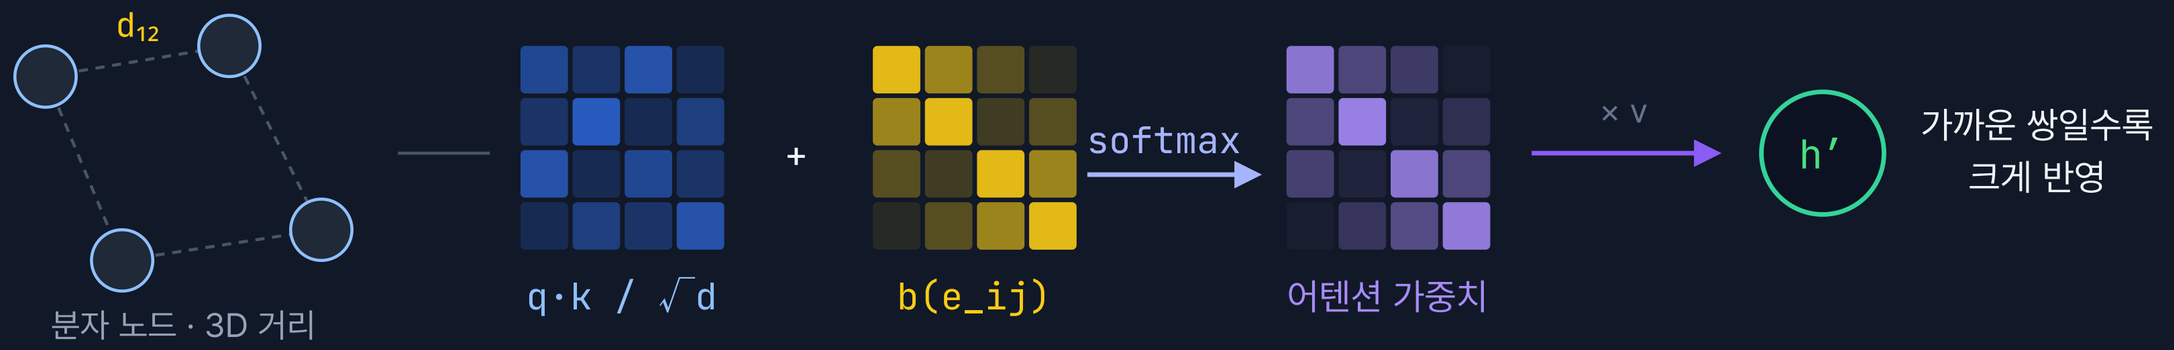
이 강의의 선택 밀도 · CED는 스칼라 → A로 충분 · 다음 장의 Graphormer-3D도 거리 · 각도만 쓰는 불변 모델

10-2 · GRAPHORMER-3D

Graphormer-3D: 3D 거리를 어텐션 편향(attention bias)으로 입력

$$\alpha_{ij} = \mathrm{softmax}_j\left(q_i \cdot k_j \,/\, \sqrt{d} + b_{ij} \right) \quad \cdot \quad b_{ij} = W_h\, e_{ij}$$

e_{ij} = 거리 · 각도 등 엣지 특징 · 헤드 h마다 다른 편향



전역 어텐션

모든 노드쌍이 한 층에서 정보 교환 — 메시지 패싱의 L홉(hop) 한계와 과평활 회피

3D 인코딩

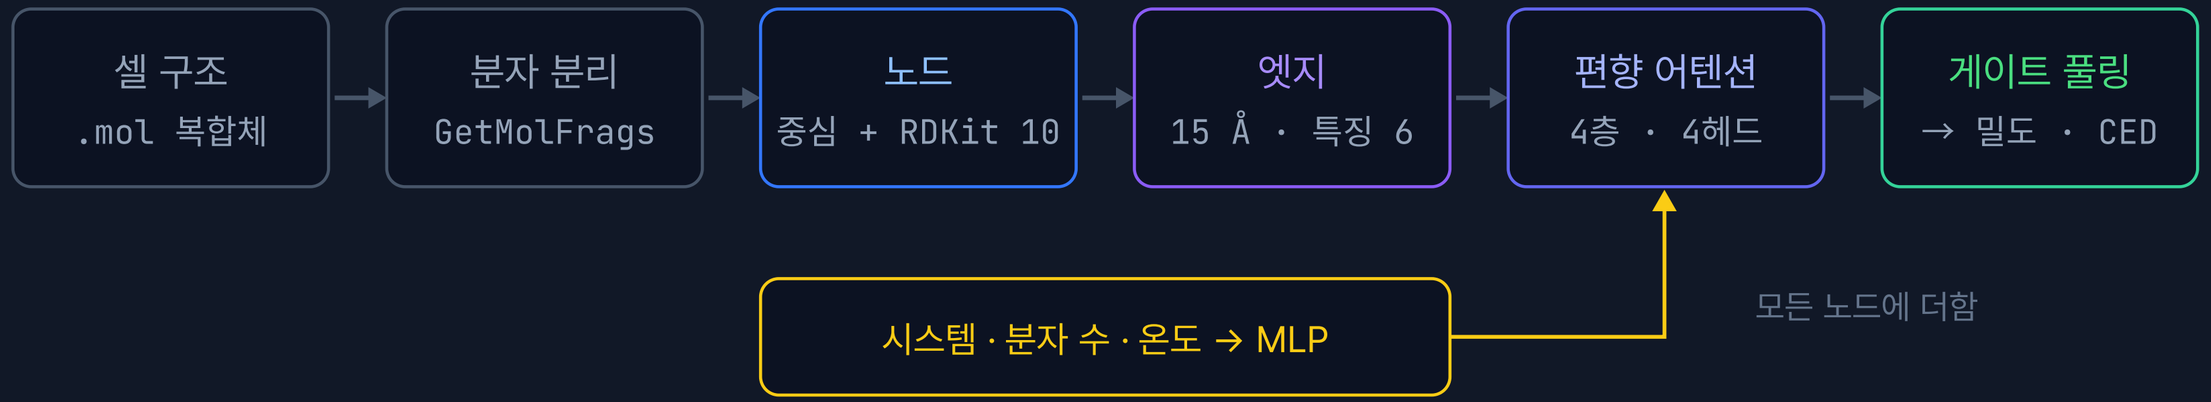
원 논문: 거리를 가우스 기저로 전개해 편향 생성 — 거리만 쓰므로 회전 불변

이 과정의 구현

4층 · 4헤드 · 엣지 특징 6개를 선형 사영해 헤드별 편향 · 게이트 어텐션 풀링(attentional aggregation)

10-2 · MODEL INPUT

바인더 셀 하나가 모델을 통과하는 경로



노드 = 분자

원자 좌표 평균을 위치로 · RDKit 기술자(descriptor) 10개(분자량 · TPSA(topological polar surface area) · LogP(옥탄올–물 분배계수) …)를 특징으로

엣지 = 분자쌍

중심 거리 15 Å 이내 · 거리 · 각도 · 수소결합 · π–π · LogP 차이 · Tanimoto 유사도

시스템 조건

분자 수 · 온도는 셀 전체의 값 — 노드별 입력 대신 MLP(multilayer perceptron)로 한 번 변환 후 모든 노드에 합산

9주차와 연결 노드 · 엣지 · 시스템 특징 목록과 ablation 결과는 9주차 수퍼그래프 사례에서 소개 — 여기서는 모델 내부 흐름만 설명

10-2 · NODE · SYSTEM FEATURES

같은 노드 · 시스템 피처를 트리 모델용 32개로 집계

분자종 s · 개수 n_s · 기술자 X_s

$$\mathrm{sum}_X = \Sigma_s \, n_s \, X_s$$

$$\mathrm{mean}_X = \mathrm{sum}_X \, / \, N_{\mathrm{frag}}$$

$$\mathrm{std}_X = \sqrt{\left(\Sigma_s \, n_s \, (X_s - \mathrm{mean}_X)^2 \, / \, N_{\mathrm{frag}} \right)}$$

기술자 10 × {mean, sum, std} + {N_{frag}, T} = **32**

	Graphormer-3D	XGBoost · RF(random forest)
분자 표현	노드 하나씩 유지	분자 수 가중 통계로 집계
3D 배치	엣지 거리 · 각도	없음 (위상만)
입력 파일	좌표가 있는 셀 구조	.mol 위상 + 분자 개수
플랫폼 위치	연구 경로	운영 경로 · 피처셋 V7

두 경로를 함께 두는 이유 트리 모델 = 기준선(baseline) — 새 모델 · 피처셋은 challenger로 학습 · 기존 champion보다 holdout 성능이 높을 때만 승격

실측 우리 벌크 165건으로 학습한 V7 밀도 challenger — holdout RMSE(root mean square error) 0.0078 (계획서 §9 · 1차 structural_challenger 실행)

10-3

MD 데이터 학습

10분 · MD 결과로 GNN 학습 · 검증

10-3 · MD DATASET

MD 결과 → 학습 샘플 변환 과정



입력 · 설계 단계에 아는 값만

조성(분자종별 개수) · 온도 · 분자 구조 — MD 실행 후에야 얻는 값은 제외 (9주차 누수(leakage) 원칙)

라벨 · MD 출력에서만

밀도 · CED — 후처리 CSV의 실험 ID로 입력과 결합

힘장 태그 · 필수

사전학습 5,346행은 COMPASS III · 우리 벌크 165행은 GAFF2(General AMBER Force Field 2) + AM1-BCC(Austin Model 1 – bond charge correction) — 절대값 차이 → 행마다 태그 부여

그룹 키 · 소재 단위

첨가제 소재(리그닌 · SBS · 석회 …)로 묶어 같은 소재의 학습 · 검증 동시 포함 방지

주의 두 데이터의 CED는 정의와 단위가 달라 혼합 학습에서 보류 — 혼합은 밀도부터

10-3 · POOLING

두 번의 풀링으로 혼합물 표현 구성

$$z_{mol} = \Sigma_v\ h_v \quad \cdot \quad z_{mix} = \Sigma_i\ c_i\ z_{mol,i} \quad \cdot \quad \hat{y} = \mathrm{MLP}([\ z_{mix}\ ,\ T\ ,\ 조건\ ])$$

노드 → 분자

합 · 평균 · attention 풀링 · 크기 의존 물성은 합이 유리

분자 → 혼합물

조성 비율 c_i 로 가중합 — 비율 합은 1로 고정

조건 결합

온도 · 첨가제 함량은 풀링 뒤에 이어 붙여 MLP로 회귀

다중 물성 동시 학습(multi-task learning)

밀도 · CED · 점도를 한 모델의 여러 출력으로 설정 → 적은 데이터에서 물성 간 정보 공유 — 손실 가중치는 오차 규모로 정규화

라벨 스케일

점도처럼 자릿수가 넓은 물성은 log 변환 후 학습 · 보고 시 역변환

10-3 · TRAINING

학습 루프와 조정 순서

PyTorch Geometric

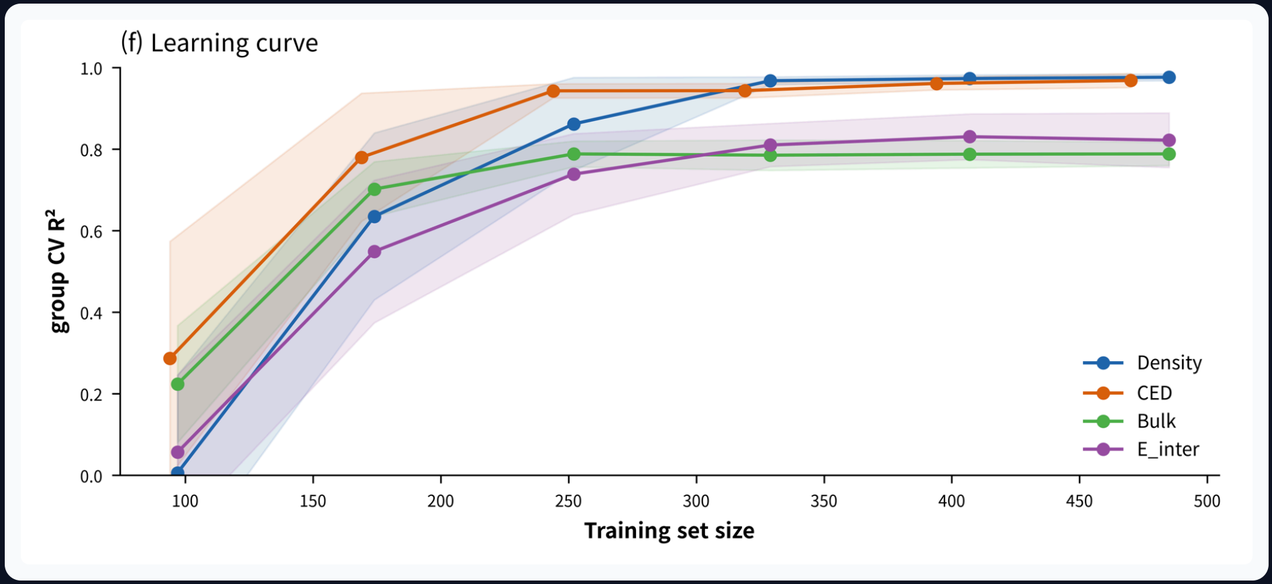
```
for epoch in range(200):
    model.train()
    for batch in train_loader:
        pred = model(batch)
        loss = F.mse_loss(pred, batch.y)
        loss.backward()
        opt.step(); opt.zero_grad()
    val = evaluate(model, val_loader)
    scheduler.step(val)
    early_stop.update(val, model)
```

조정 순서	권장 범위
01 학습률	1e-4 ~ 3e-3
02 층 수 L	3 ~ 5
03 은닉 차원	64 ~ 256
04 배치 크기	16 ~ 128
05 정규화	dropout 0 ~ 0.2

재현성 난수 시드 · 데이터 버전 · 하이퍼파라미터를 한 설정 파일로 묶어 저장 — MD의 실험 ID와 같은 역할

10-3 · VALIDATION

검증 기준 — 처음 보는 소재 · 데이터 양



학습곡선 · 트리 대리모델 group CV(그룹 교차검증) (GNN 결과 아님) · fig_reliability (f)

소재 홀드아웃

한 소재를 통째로 빼고 학습 — 처음 보는 첨가제에서 따로 평가

다중 시드

최종 학습을 시드 여러 개로 반복 → 평균 ± 표준편차

데이터 충분성

밀도 · CED는 수백 건에서 R^2 0.97 전후 수렴 · bulk · E_inter는 0.8 전후 정체

힘장 혼합

밀도 holdout RMSE — GAFF2만 0.0085 · 혼합(MDML COMPASS 5,346행 + 우리 GAFF2 165건) 0.0109 · 계획서 §9 2차 스토어 학습(train_from_store) 값 → #15의 0.0078(1차 실행)과 실행 다름 · 데이터가 많다고 항상 개선되지는 않음

10-4

불확실성과 능동학습

12분 · 불확실성이 큰 영역 식별 · 다음 계산 선택

10-4 · UNCERTAINTY

두 종류의 불확실성

알레아토릭(aleatoric) · 데이터 자체의 잡음

MD 시드 간 편차에서 오는 부분 — 데이터를 더 모아도 줄지 않음

에피스테믹(epistemic) · 학습 데이터 부족에서 오는 불확실성

학습 데이터가 없는 영역에서 증가 — 계산 추가 시 감소 · 능동학습의 표적

딥 앙상블(deep ensemble)

시드만 바꿔 5개 학습 · 예측 평균과 분산 · 가장 안정적

MC(Monte Carlo) dropout

추론 시 dropout을 켠 채 여러 번 예측 · 비용 낮음

이분산 회귀 · heteroscedastic

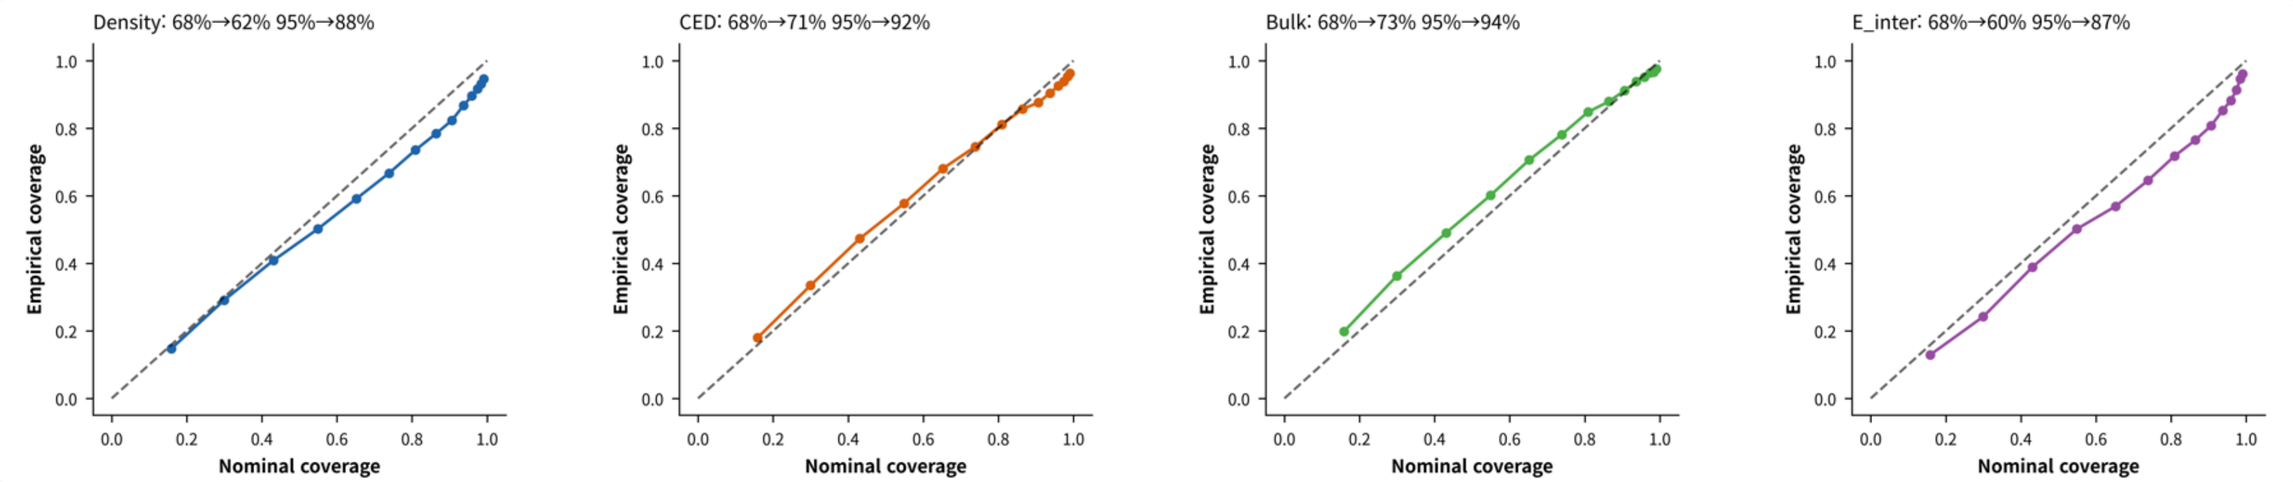
모델이 평균과 분산을 함께 출력 · 알레아토릭 항을 직접 학습

보정 확인 "68% 구간 안의 실제 포함 비율 = 68%" 여부를 검증 폴드로 확인 — 어긋나면 온도 스케일링(temperature scaling)으로 보정

10-4 흐름 능동학습으로 줄일 수 있는 불확실성 = 에피스테믹 — 다음 장: 그 σ의 실제 적중 여부부터 확인

10-4 · CALIBRATION

보정 곡선(calibration curve)으로 예측 구간 적중 여부 확인



Density	약간 과신
68% → 62%	
95% → 88%	

CED	양호
68% → 71%	
95% → 92%	

Bulk	양호
68% → 73%	
95% → 94%	

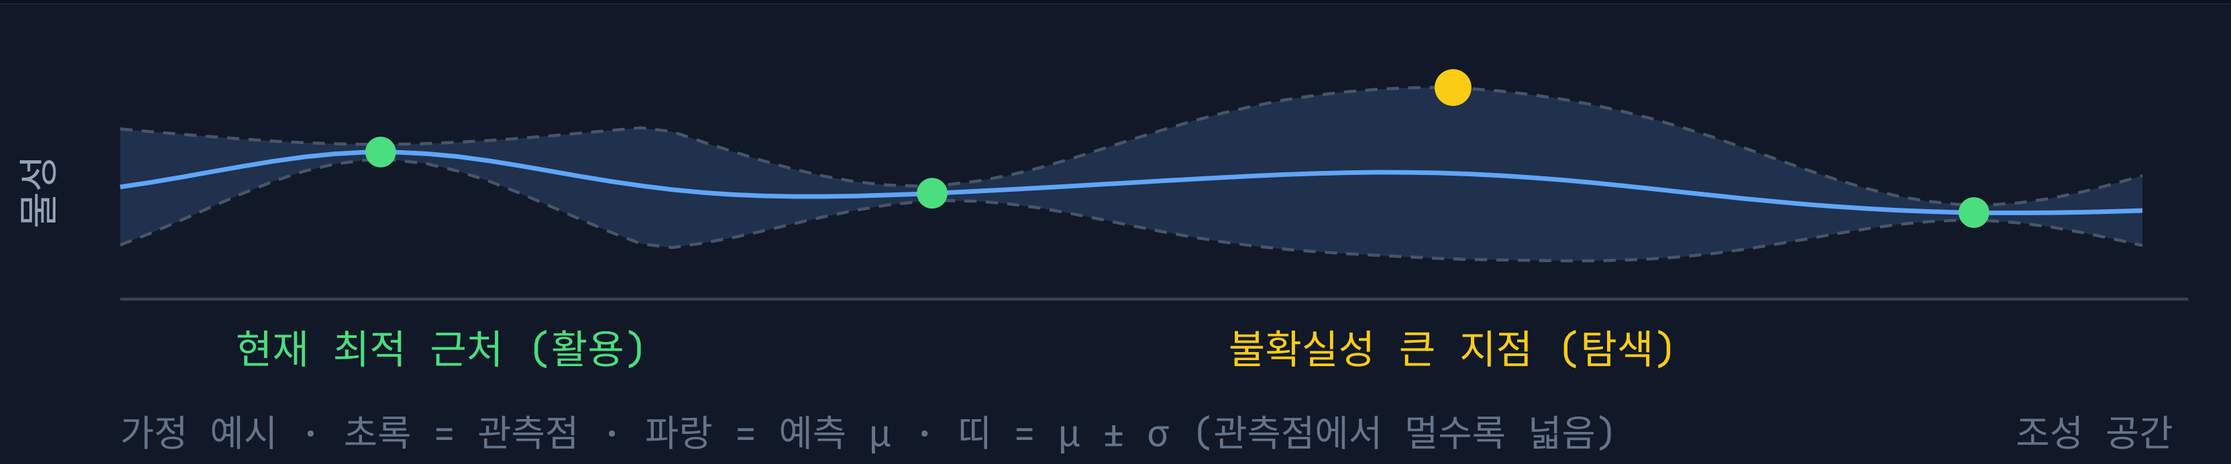
E_inter	과신
68% → 60%	
95% → 87%	

읽는 법 곡선이 대각선 아래 = 구간이 좁음 — 과신(over-confidence) · 획득함수가 이 σ를 그대로 사용 → 보정 우선 확인

GP(Gaussian process) 대리모델 · 검증 폴드 커버리지 · fig_reliability · comid_reliability.md

10-4 · ACQUISITION

획득함수 — 탐색(exploration)과 활용(exploitation)의 균형



EI · 기대 개선(expected improvement)

현재 최고를 넘어설 기대값 · 활용 쪽

UCB(upper confidence bound)

μ + κσ · κ로 균형을 직접 조절

최대 분산

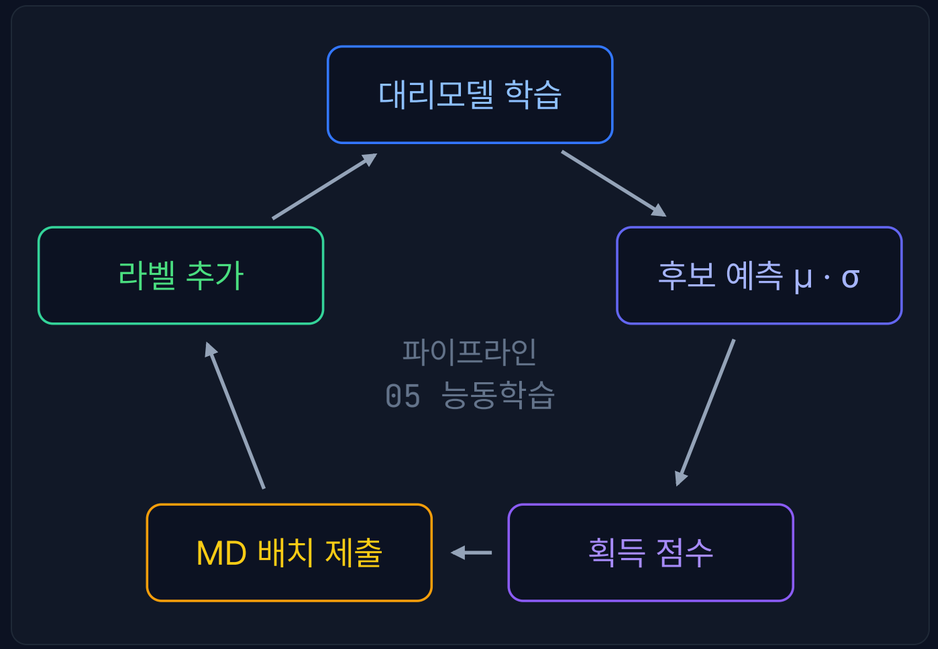
모델 개선이 목적일 때 · 순수 탐색

EHVI(expected hypervolume improvement)

표적이 여러 개일 때 · 13주차에서 다룸

다음 단계 점수가 높은 후보를 MD로 계산 → 라벨로 추가 — 이 반복 = 능동학습 루프 (다음 장)

능동학습 루프 = 파이프라인 05 단계



샘플링 전략	적용 상황	보충 B
무작위 · 격자	초기 데이터 · 비교 기준선	—
최대 분산	모델 개선이 목적	10-S5
EI · UCB	목표 물성 최적화	10-S5
배치 + 다양성	GPU 여러 장에 동시 제출	10-S6
비용 인지	후보마다 계산 비용이 다를 때	10-S7
루프 자동화	무인 반복 구조	10-S8

플랫폼 현황 새 라벨 → 재학습 → champion 비교 → 승격. 실시간 재학습은 기본 OFF · opt-in 정책

PRACTICE

실습 · 밀도 · CED 회귀 모델

PRACTICE

01 9주차 데이터셋을 PyG(PyTorch Geometric) Data 객체로 변환

02 3층 MPNN + 조성 가중 풀링 모델을 구현

03 comp_id 폴드로 학습 · 검증 후 학습 곡선 기록

04 조성 특징만 쓰는 선형 모델과 성능을 비교

DELIVERABLE

학습 곡선 · 체크포인트 · 설정 파일

예측 스크립트 — 조성 입력 → 물성 출력 함수

기준 모델(선형) 대비 성능 우위 반드시 확인

퀴즈 10주차

SUMMARY

10주차 정리

01 분자 · 결정 = 결합 그래프 · 거리 컷오프 그래프 · 메시지 패싱 L층은 L결합 거리까지 반영

02 3D 좌표는 대칭 보존 조건으로 사용 — Graphormer-3D는 거리 · 각도를 어텐션 편향으로 넣는 불변 모델

03 MD 데이터 학습은 입력 · 라벨 분리, 힘장 태그, 소재 홀드아웃이 핵심

04 불확실성은 보정을 확인한 뒤 획득함수로 다음 MD 계산을 고르는 근거

퀴즈 10주차

이어서: 10주차 보충 A 대리모델 평가와 불확실성 · 다음 주차: 11주차 문헌 고찰