COMID

WEEK 10 · 차시 10-1 ~ 10-4 · 50분

기계학습 (2) GNN과 능동학습

분자 그래프와 message passing · 등변 GNN과 Graphormer-3D · MD 데이터 학습 · 불확실성과 능동학습

윤태영 (Taeyoung Yun)

실습 · PyTorch Geometric 회귀

퀴즈 10주차

RECAP · WEEK 09

지난 주차 요약과 이번 주차의 위치

9주차 산출물

특징 · 라벨 · 폴드가 정리된 학습용 데이터셋

손으로 만든 특징의 한계

새 골격(scaffold)의 분자마다 특징 재정의

이번 주차

구조에서 표현을 직접 학습하는 그래프 신경망(GNN, graph neural network) 사용

파이프라인 6단계 중 04 대리모델(surrogate model) 학습 · 05 능동학습(active learning)에 해당

OBJECTIVE

10주차 학습목표

01 분자 · 결정을 그래프로 표현하고 메시지 패싱(message passing) 한 층의 계산을 식으로 설명

02 불변(invariance) · 등변(equivariance)의 뜻과 Graphormer-3D가 3D 거리를 넣는 방식을 설명

03 MD 결과로 학습 데이터를 구성하고 풀링(pooling) · 학습 루프 · 소재 홀드아웃(hold-out)으로 검증

04 예측 불확실성의 보정(calibration)을 확인하고 획득함수(acquisition function)로 다음 MD 계산을 선택

AGENDA

10주차 구성

10-1	분자 그래프와 message passing	12분
10-2	등변 GNN과 Graphormer-3D	16분
10-3	MD 데이터 학습	10분
10-4	불확실성과 능동학습	12분

10-1

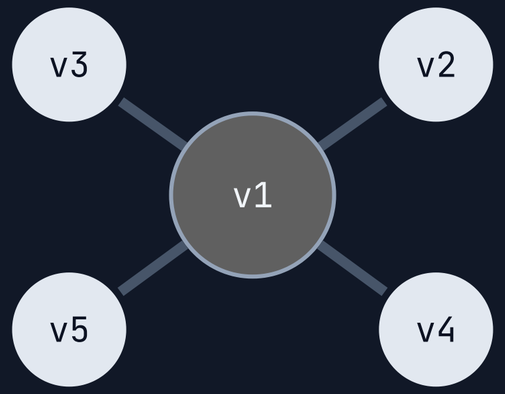
분자 그래프와 message passing

12분 · 분자 · 결정의 그래프 표현 · 이웃 정보 집계

10-1 · GRAPH

분자를 그래프로 기재

예: 메탄 CH_4 · v1 = C · v2–v5 = H



노드(node) = 원자 · 엣지(edge) = 결합

노드 특징 x_v

원소 one-hot · 혼성(hybridization, sp/sp^2/sp^3) · 형식전하(formal charge) · 고리 포함 여부 · 수소 개수 · 부분전하

엣지 특징 e_{uv}

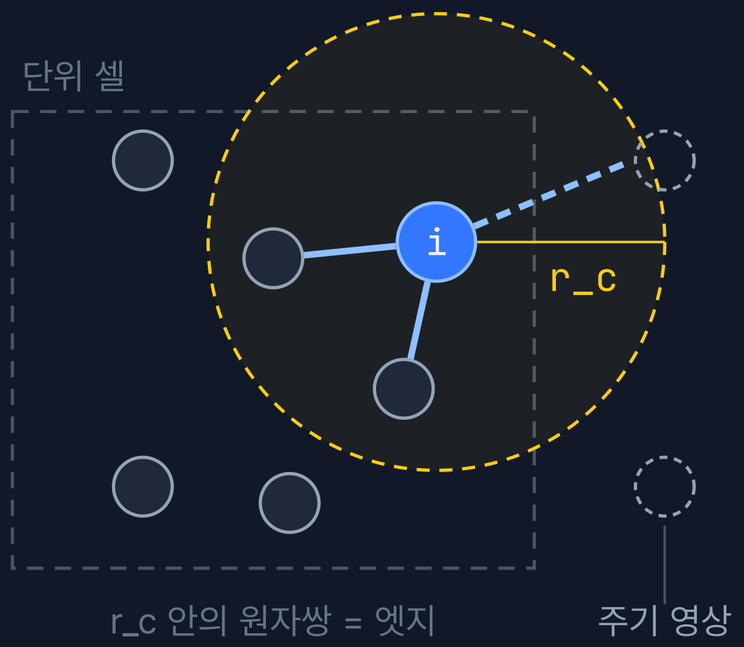
결합 차수 · 방향족 여부 · 고리 내부 여부 · (선택) 결합 길이

왜 그래프인가

원자 번호 순서를 바꿔도 같은 분자로 인식 — 순열 불변성(permutation invariance)이 구조상 자동 보장

10-1 · CRYSTAL GRAPH

결정·벌크 셀: 결합 대신 거리 기준 엣지



엣지 규칙

컷오프 반경 r_c 안의 모든 원자쌍 연결 — 셀 경계를 넘으면 주기 영상(periodic image)과 연결 (2주차 주기경계조건)

엣지 특징

결합 차수 대신 거리 d_{ij} 사용 — 가우스 기저(Gaussian basis)로 전개한 벡터로 상호작용 세기를 연속적으로 표현

분자 단위 노드

바인더처럼 거대분자 혼합물은 분자 하나를 노드로 설정 — 9주차 수퍼그래프(supergraph) 사례 · 분자쌍 15 Å 컷오프

주의

셀 한 변이 $2r_c$보다 짧으면 한 원자쌍이 여러 영상으로 중복 연결 — 엣지 생성 코드의 처리 여부 확인

10-1 · MESSAGE PASSING

메시지 패싱 한 층의 계산

$$m_v^{(l)} = \sum_{u \in N(v)} M(h_u^{(l)}, e_{uv}) \quad \cdot \quad h_v^{(l+1)} = U(h_v^{(l)}, m_v^{(l)})$$

M = 메시지 함수 · U = 갱신 함수 · N(v) = v의 이웃 원자 집합



L층 = L결합 떨어진 원자까지 정보가 도달

보통 L = 3 ~ 5

대표 구조

GCN(graph convolutional network) · GIN(graph isomorphism network) · MPNN(message passing neural network) · GAT(graph attention network) — 메시지 · 갱신 함수의 선택 차이

층이 너무 많으면

모든 노드 표현이 비슷해지는 과평활(over-smoothing) — 잔차 연결(residual connection)로 완화

엣지 활용

방향족 · 결합 차수를 메시지에 포함해야 고리 구조 구분 가능

10-1 · CHECK

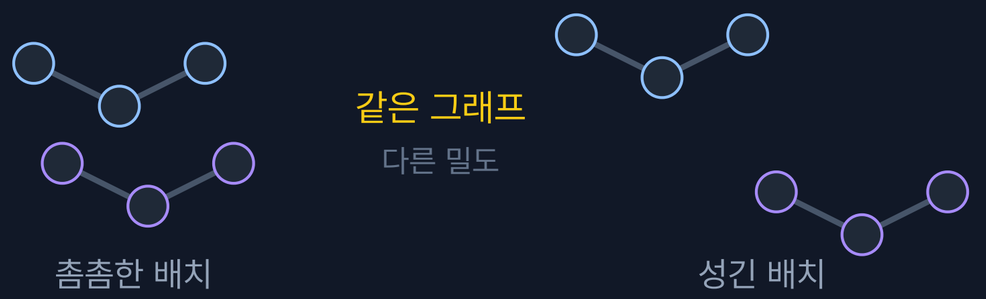
위상 그래프만으로는 3차원 배치 구분 불가

확인 질문

01 원자 번호를 바꿔 입력해도 예측이 같은 이유는?

02 메시지 패싱이 3층일 때 한 원자가 반영하는 결합 거리는?

03 벤젠과 사이클로헥세인 구분에 필요한 노드 · 엣지 특징은?



남는 한계

결합 위상에는 분자 사이 거리와 입체 배치 정보 없음 — 밀도처럼 패킹이 결정하는 물성은 좌표 필수

10-2로 좌표를 입력에 포함 · 구조를 회전 · 이동해도 스칼라 출력(밀도)은 같은 답 = 불변성(invariance) · 벡터 · 힘 출력은 함께 회전 = 등변성(equivariance)

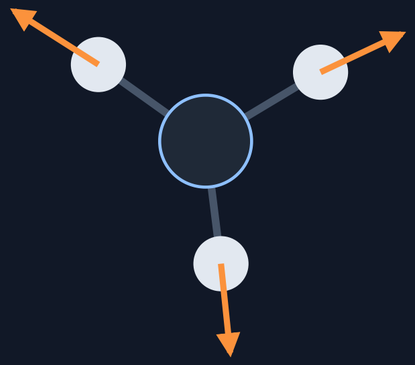
10-2

등변 GNN과 Graphormer-3D

16분 · 대칭을 보존하는 3D 좌표 사용법

10-2 · SYMMETRY

좌표 사용의 전제 — 회전 · 이동 대칭 조건

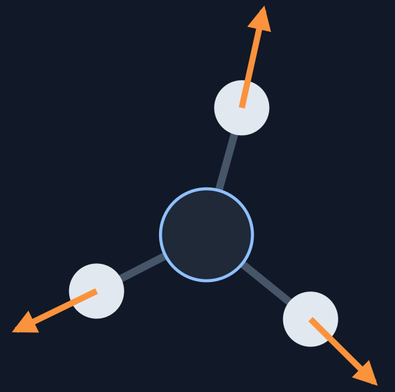


원래 좌표 x

회전 R · 이동 t

에너지 E · 밀도 → 그대로

힘 F (주황 화살표) → 함께 회전



돌린 좌표 Rx + t

불변 · invariance

$$\mathrm{f}(Rx + t) = \mathrm{f}(x)$$

스칼라 출력 — 밀도 · CED(cohesive energy density) · 에너지는 좌표 회전 후에도 같은 값

등변 · equivariance

$$\mathrm{f}(Rx + t) = R\,\mathrm{f}(x)$$

벡터 출력 — 힘 · 쌍극자는 좌표와 함께 회전 · ML 힘장의 조건

좌표를 그대로 넣으면 같은 구조를 회전한 입력마다 다른 답 — 회전 증강(augmentation)으로 근사 가능하나 필요 데이터 대폭 증가

10-2 · EQUIVARIANT GNN

대칭 보존의 두 가지 설계

A · 불변 특징만 사용

$$\mathrm{m}_{ij} = \varphi(h_i, h_j, d_{ij}, \theta_{ijk})$$

입력	원자 간 거리 d_{ij} · 결합각 θ_{ijk} — 회전해도 변하지 않는 양
대표	SchNet (거리) · DimeNet (거리 + 각도) · Graphormer-3D
출력	스칼라 물성에 적합 — 힘 = 에너지 미분 F = −∇E
비용	낮음 — 층마다 스칼라 특징만 갱신

B · 벡터도 함께 전달

$$x_i' = x_i + C \sum_j (x_i - x_j)\, \varphi_x(\mathrm{m}_{ij})$$

입력	좌표 · 벡터 특징을 층마다 갱신 — 상대 벡터만 쓰므로 등변
대표	EGNN(E(n)-equivariant GNN, 위 식) · PaiNN · NequIP
출력	힘 · 쌍극자를 직접 등변으로 — ML 힘장(MLIP, machine-learned interatomic potential)의 주류
비용	높음 — 벡터 · 텐서 특징을 층마다 함께 연산

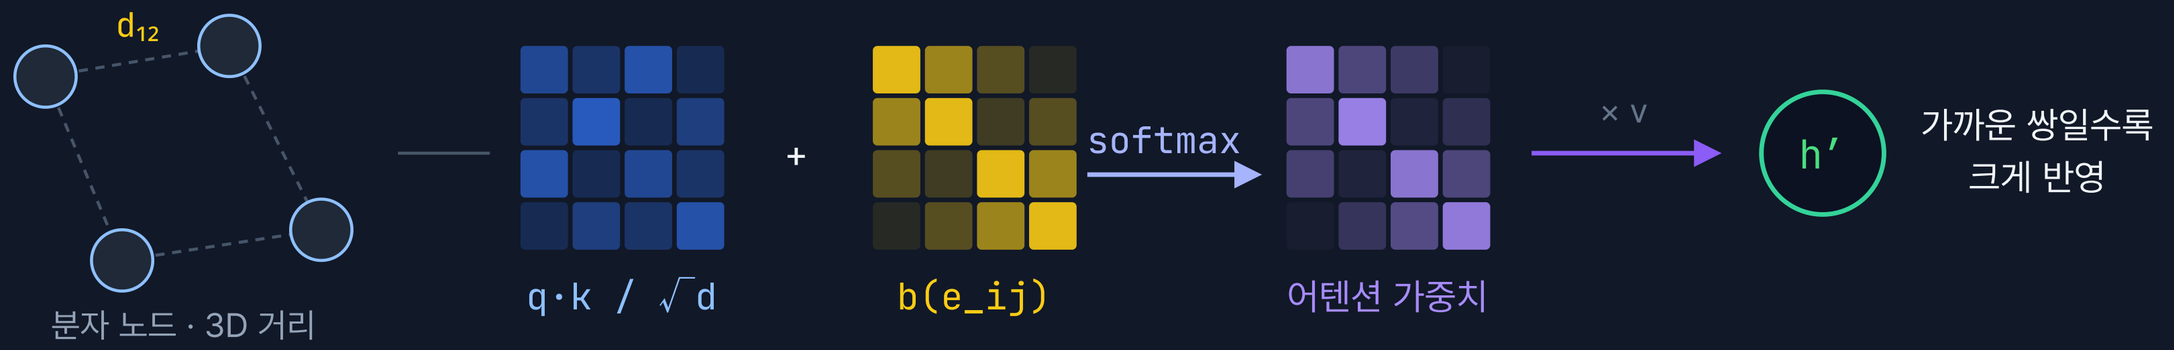
이 강의의 선택 밀도 · CED는 스칼라 → A로 충분 · 다음 장의 Graphormer-3D도 거리 · 각도만 쓰는 불변 모델

10-2 · GRAPHORMER-3D

Graphormer-3D: 3D 거리를 어텐션 편향(attention bias)으로 입력

$$\alpha_{ij} = \mathrm{softmax}_j\left(q_i \cdot k_j \,/\, \sqrt{d} + b_{ij} \right) \quad \cdot \quad b_{ij} = W_h\, e_{ij}$$

e_{ij} = 거리 · 각도 등 엣지 특징 · 헤드 h마다 다른 편향



전역 어텐션

모든 노드쌍이 한 층에서 정보 교환 — 메시지 패싱의 L홉(hop) 한계와 과평활 회피

3D 인코딩

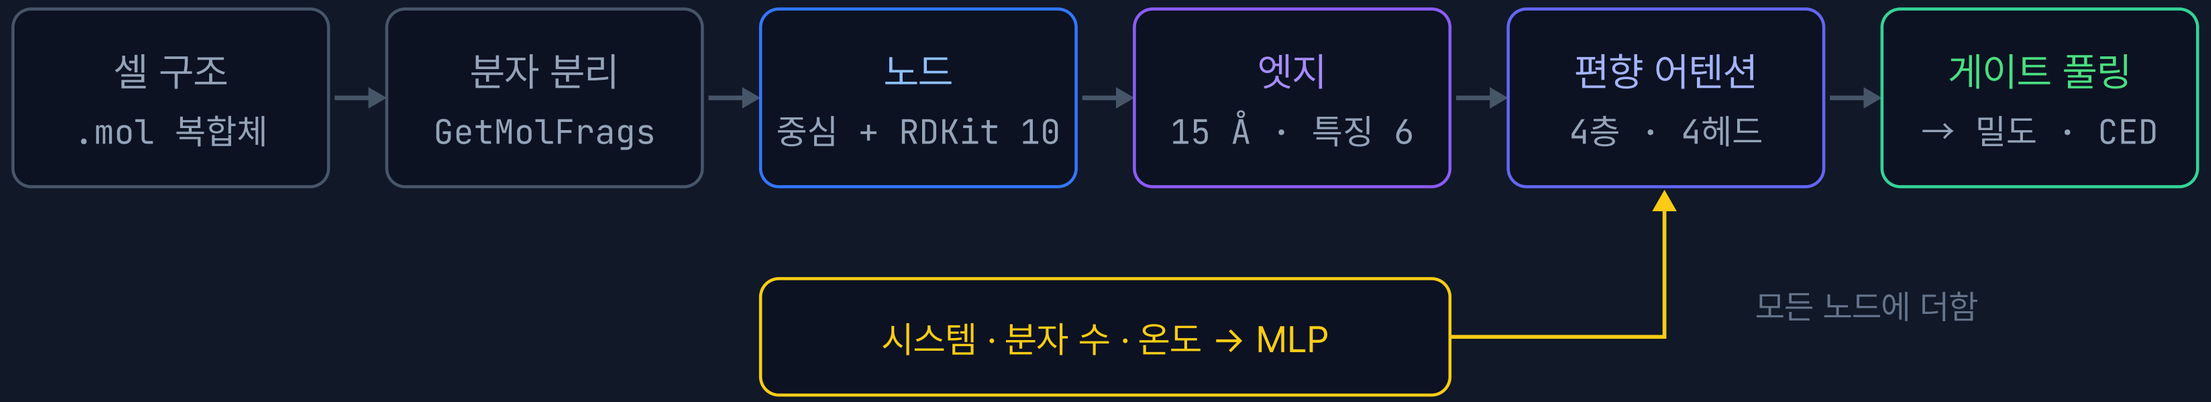
원 논문: 거리를 가우스 기저로 전개해 편향 생성 — 거리만 쓰므로 회전 불변

이 과정의 구현

4층 · 4헤드 · 엣지 특징 6개를 선형 사영해 헤드별 편향 · 게이트 어텐션 풀링(attentional aggregation)

10-2 · MODEL INPUT

바인더 셀 하나가 모델을 통과하는 경로



노드 = 분자

원자 좌표 평균을 위치로 · RDKit 기술자(descriptor) 10개(분자량 · TPSA(topological polar surface area) · LogP(옥탄올–물 분배계수) …)를 특징으로

엣지 = 분자쌍

중심 거리 15 Å 이내 · 거리 · 각도 · 수소결합 · π–π · LogP 차이 · Tanimoto 유사도

시스템 조건

분자 수 · 온도는 셀 전체의 값 — 노드별 입력 대신 MLP(multilayer perceptron)로 한 번 변환 후 모든 노드에 합산

9주차와 연결 노드 · 엣지 · 시스템 특징 목록과 ablation 결과는 9주차 수퍼그래프 사례에서 소개 — 여기서는 모델 내부 흐름만 설명

10-2 · NODE · SYSTEM FEATURES

같은 노드 · 시스템 피처를 트리 모델용 32개로 집계

분자종 s · 개수 n_s · 기술자 X_s

$$\mathrm{sum}_X = \Sigma_s \, n_s \, X_s$$

$$\mathrm{mean}_X = \mathrm{sum}_X \, / \, N_{\mathrm{frag}}$$

$$\mathrm{std}_X = \sqrt{\left(\Sigma_s \, n_s \, (X_s - \mathrm{mean}_X)^2 \, / \, N_{\mathrm{frag}} \right)}$$

기술자 10 × {mean, sum, std} + {N_{frag}, T} = **32**

	Graphormer-3D	XGBoost · RF(random forest)
분자 표현	노드 하나씩 유지	분자 수 가중 통계로 집계
3D 배치	엣지 거리 · 각도	없음 (위상만)
입력 파일	좌표가 있는 셀 구조	.mol 위상 + 분자 개수
플랫폼 위치	연구 경로	운영 경로 · 피처셋 V7

두 경로를 함께 두는 이유 트리 모델 = 기준선(baseline) — 새 모델 · 피처셋은 challenger로 학습 · 기존 champion보다 holdout 성능이 높을 때만 승격

실측 우리 벌크 165건으로 학습한 V7 밀도 challenger — holdout RMSE(root mean square error) 0.0078 (계획서 §9 · 1차 structural_challenger 실행)

10-3

MD 데이터 학습

10분 · MD 결과로 GNN 학습 · 검증

10-3 · MD DATASET

MD 결과 → 학습 샘플 변환 과정



입력 · 설계 단계에 아는 값만

조성(분자종별 개수) · 온도 · 분자 구조 — MD 실행 후에야 얻는 값은 제외 (9주차 누수(leakage) 원칙)

라벨 · MD 출력에서만

밀도 · CED — 후처리 CSV의 실험 ID로 입력과 결합

힘장 태그 · 필수

사전학습 5,346행은 COMPASS III · 우리 벌크 165행은 GAFF2(General AMBER Force Field 2) + AM1-BCC(Austin Model 1 – bond charge correction) — 절대값 차이 → 행마다 태그 부여

그룹 키 · 소재 단위

첨가제 소재(리그닌 · SBS · 석회 …)로 묶어 같은 소재의 학습 · 검증 동시 포함 방지

주의 두 데이터의 CED는 정의와 단위가 달라 혼합 학습에서 보류 — 혼합은 밀도부터

10-3 · POOLING

두 번의 풀링으로 혼합물 표현 구성

$$z_{mol} = \Sigma_v\ h_v \quad \cdot \quad z_{mix} = \Sigma_i\ c_i\ z_{mol,i} \quad \cdot \quad \hat{y} = \mathrm{MLP}([\ z_{mix}\ ,\ T\ ,\ 조건\ ])$$

노드 → 분자

합 · 평균 · attention 풀링 · 크기 의존 물성은 합이 유리

분자 → 혼합물

조성 비율 c_i 로 가중합 — 비율 합은 1로 고정

조건 결합

온도 · 첨가제 함량은 풀링 뒤에 이어 붙여 MLP로 회귀

다중 물성 동시 학습(multi-task learning)

밀도 · CED · 점도를 한 모델의 여러 출력으로 설정 → 적은 데이터에서 물성 간 정보 공유 — 손실 가중치는 오차 규모로 정규화

라벨 스케일

점도처럼 자릿수가 넓은 물성은 log 변환 후 학습 · 보고 시 역변환

10-3 · TRAINING

학습 루프와 조정 순서

PyTorch Geometric

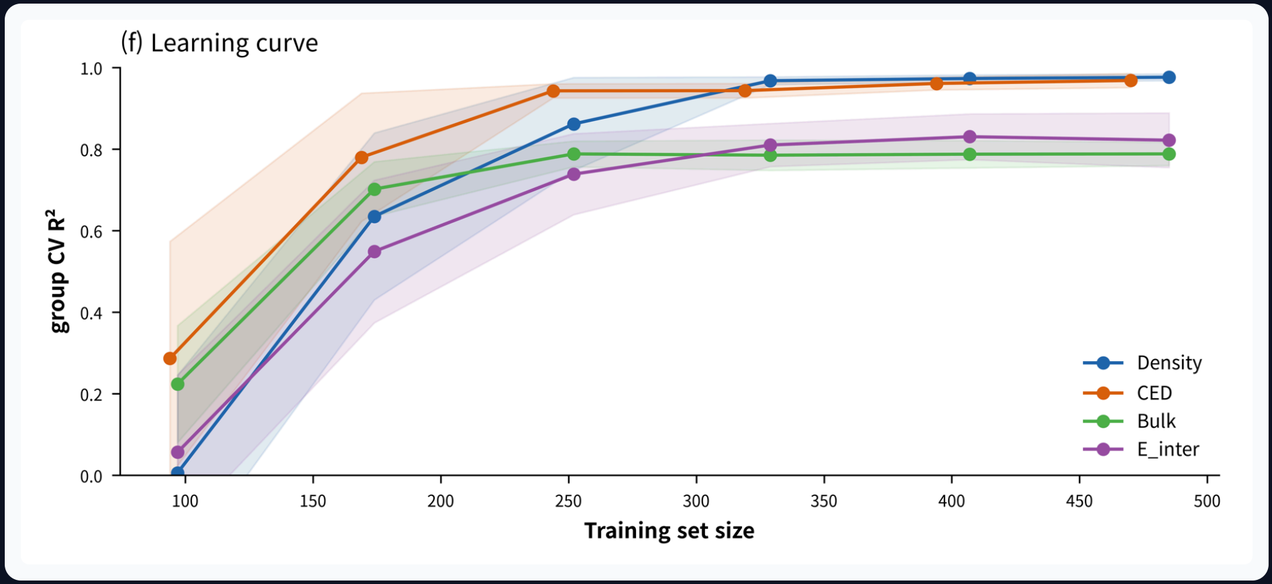
```
for epoch in range(200):
    model.train()
    for batch in train_loader:
        pred = model(batch)
        loss = F.mse_loss(pred, batch.y)
        loss.backward()
        opt.step(); opt.zero_grad()
    val = evaluate(model, val_loader)
    scheduler.step(val)
    early_stop.update(val, model)
```

조정 순서	권장 범위
01 학습률	1e-4 ~ 3e-3
02 층 수 L	3 ~ 5
03 은닉 차원	64 ~ 256
04 배치 크기	16 ~ 128
05 정규화	dropout 0 ~ 0.2

재현성 난수 시드 · 데이터 버전 · 하이퍼파라미터를 한 설정 파일로 묶어 저장 — MD의 실험 ID와 같은 역할

10-3 · VALIDATION

검증 기준 — 처음 보는 소재 · 데이터 양



학습곡선 · 트리 대리모델 group CV(그룹 교차검증) (GNN 결과 아님) · fig_reliability (f)

소재 홀드아웃

한 소재를 통째로 빼고 학습 — 처음 보는 첨가제에서 따로 평가

다중 시드

최종 학습을 시드 여러 개로 반복 → 평균 ± 표준편차

데이터 충분성

밀도 · CED는 수백 건에서 R^2 0.97 전후 수렴 · bulk · E_inter는 0.8 전후 정체

힘장 혼합

밀도 holdout RMSE — GAFF2만 0.0085 · 혼합(MDML COMPASS 5,346행 + 우리 GAFF2 165건) 0.0109 · 계획서 §9 2차 스토어 학습(train_from_store) 값 → #15의 0.0078(1차 실행)과 실행 다름 · 데이터가 많다고 항상 개선되지는 않음

10-4

불확실성과 능동학습

12분 · 불확실성이 큰 영역 식별 · 다음 계산 선택

10-4 · UNCERTAINTY

두 종류의 불확실성

알레아토릭(aleatoric) · 데이터 자체의 잡음

MD 시드 간 편차에서 오는 부분 — 데이터를 더 모아도 줄지 않음

에피스테믹(epistemic) · 학습 데이터 부족에서 오는 불확실성

학습 데이터가 없는 영역에서 증가 — 계산 추가 시 감소 · 능동학습의 표적

딥 앙상블(deep ensemble)

시드만 바꿔 5개 학습 · 예측 평균과 분산 · 가장 안정적

MC(Monte Carlo) dropout

추론 시 dropout을 켠 채 여러 번 예측 · 비용 낮음

이분산 회귀 · heteroscedastic

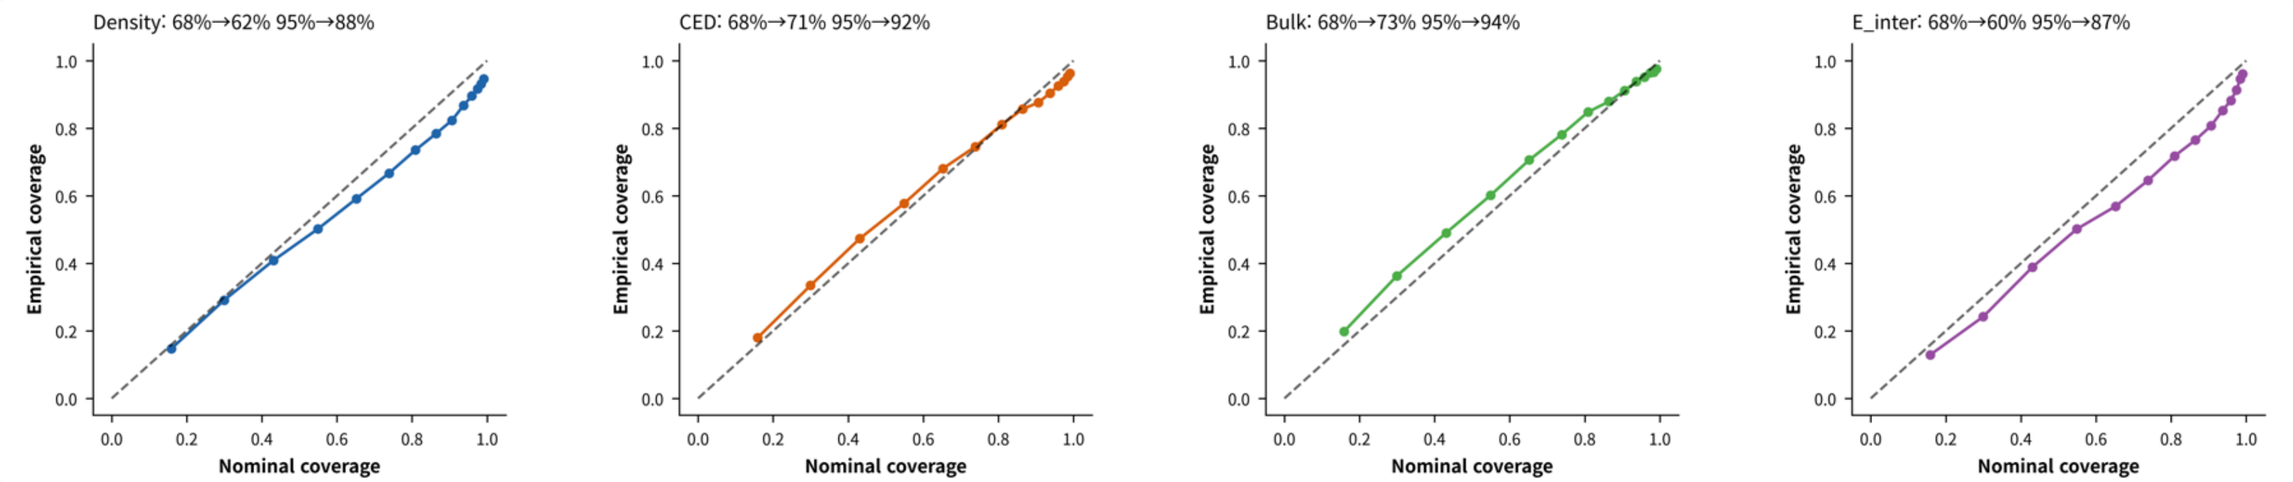
모델이 평균과 분산을 함께 출력 · 알레아토릭 항을 직접 학습

보정 확인 "68% 구간 안의 실제 포함 비율 = 68%" 여부를 검증 폴드로 확인 — 어긋나면 온도 스케일링(temperature scaling)으로 보정

10-4 흐름 능동학습으로 줄일 수 있는 불확실성 = 에피스테믹 — 다음 장: 그 σ의 실제 적중 여부부터 확인

10-4 · CALIBRATION

보정 곡선(calibration curve)으로 예측 구간 적중 여부 확인



Density	약간 과신
68% → 62%	
95% → 88%	

CED	양호
68% → 71%	
95% → 92%	

Bulk	양호
68% → 73%	
95% → 94%	

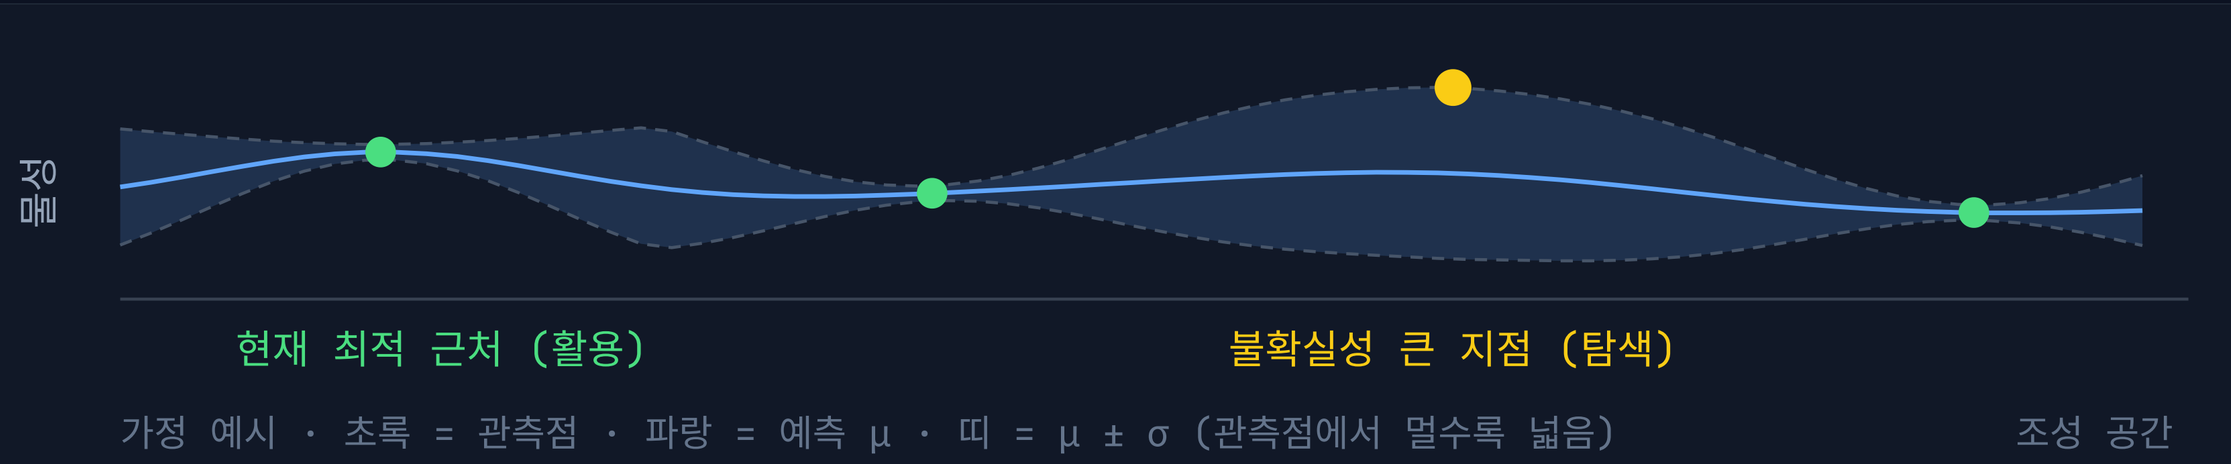
E_inter	과신
68% → 60%	
95% → 87%	

읽는 법 곡선이 대각선 아래 = 구간이 좁음 — 과신(over-confidence) · 획득함수가 이 σ를 그대로 사용 → 보정 우선 확인

GP(Gaussian process) 대리모델 · 검증 폴드 커버리지 · fig_reliability · comid_reliability.md

10-4 · ACQUISITION

획득함수 — 탐색(exploration)과 활용(exploitation)의 균형



EI · 기대 개선(expected improvement)

현재 최고를 넘어설 기대값 · 활용 쪽

UCB(upper confidence bound)

μ + κσ · κ로 균형을 직접 조절

최대 분산

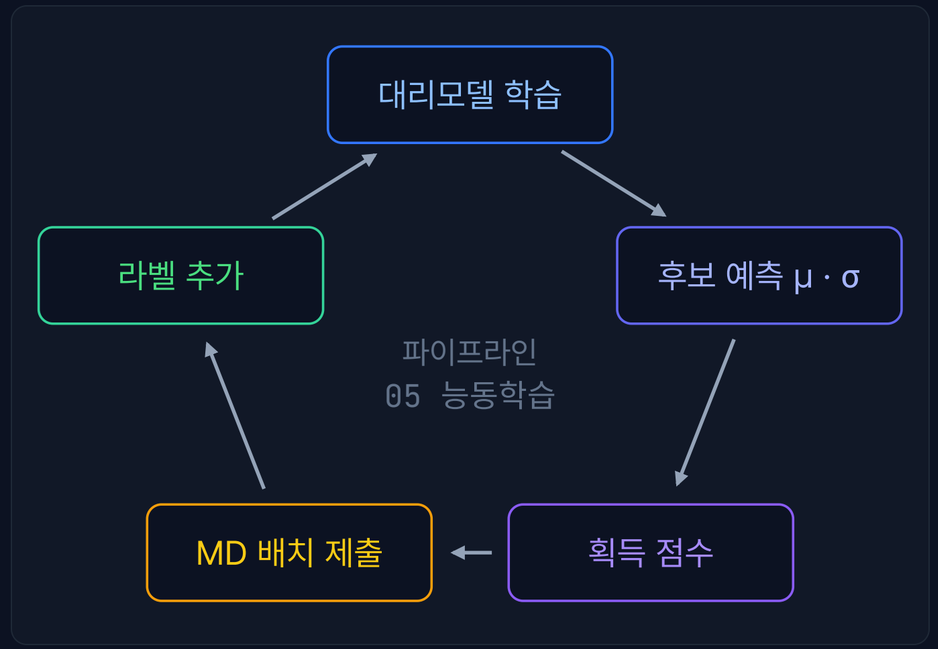
모델 개선이 목적일 때 · 순수 탐색

EHVI(expected hypervolume improvement)

표적이 여러 개일 때 · 13주차에서 다룸

다음 단계 점수가 높은 후보를 MD로 계산 → 라벨로 추가 — 이 반복 = 능동학습 루프 (다음 장)

능동학습 루프 = 파이프라인 05 단계



샘플링 전략	적용 상황	보충 B
무작위 · 격자	초기 데이터 · 비교 기준선	—
최대 분산	모델 개선이 목적	10-S5
EI · UCB	목표 물성 최적화	10-S5
배치 + 다양성	GPU 여러 장에 동시 제출	10-S6
비용 인지	후보마다 계산 비용이 다를 때	10-S7
루프 자동화	무인 반복 구조	10-S8

플랫폼 현황 새 라벨 → 재학습 → champion 비교 → 승격. 실시간 재학습은 기본 OFF · opt-in 정책

PRACTICE

실습 · 밀도 · CED 회귀 모델

PRACTICE

01 9주차 데이터셋을 PyG(PyTorch Geometric) Data 객체로 변환

02 3층 MPNN + 조성 가중 풀링 모델을 구현

03 comp_id 폴드로 학습 · 검증 후 학습 곡선 기록

04 조성 특징만 쓰는 선형 모델과 성능을 비교

DELIVERABLE

학습 곡선 · 체크포인트 · 설정 파일

예측 스크립트 — 조성 입력 → 물성 출력 함수

기준 모델(선형) 대비 성능 우위 반드시 확인

퀴즈 10주차

SUMMARY

10주차 정리

01 분자 · 결정 = 결합 그래프 · 거리 컷오프 그래프 · 메시지 패싱 L층은 L결합 거리까지 반영

02 3D 좌표는 대칭 보존 조건으로 사용 — Graphormer-3D는 거리 · 각도를 어텐션 편향으로 넣는 불변 모델

03 MD 데이터 학습은 입력 · 라벨 분리, 힘장 태그, 소재 홀드아웃이 핵심

04 불확실성은 보정을 확인한 뒤 획득함수로 다음 MD 계산을 고르는 근거

퀴즈 10주차

이어서: 10주차 보충 A 대리모델 평가와 불확실성 · 다음 주차: 11주차 문헌 고찰

APPX

부록 · 참고 자료

본강의 흐름에서 빠진 슬라이드와 원문 보존

APPENDIX · ORIGINAL TEXT

이전 구성의 원문 문구

01 그래프 신경망 기초

02 분자 그래프 · 메시지 패싱 · 혼합물 풀링 · 학습 루프

03 분자를 노드 · 엣지 특징이 붙은 그래프로 표현

04 분자 벡터를 조성으로 묶어 혼합물 물성을 회귀

05 학습 루프와 하이퍼파라미터를 통제된 방식으로 조정

06 분자 그래프 표현

07 메시지 패싱 구조

08 혼합물 풀링과 물성 회귀

09 학습 루프와 하이퍼파라미터