COMID

WEEK 12 · 차시 12-1 ~ 12-4 · 50분

자율 탐색 파이프라인 (1) 구조와 데이터 큐레이션

파이프라인 구조 · 후보 분자 생성 · PostgreSQL 데이터 큐레이션(data curation) · 이상치 처리 · 재현성(reproducibility)

윤태영 (Taeyoung Yun)

실습 · 후보 격자와 데이터셋 구축

퀴즈 12주차

RECAP · WEEK 02-11

2–11주차 산출물 회고

쌓인 것

조성별 · 온도별 물성값 · 오차 · 궤적(trajectory) (2–8주차) · 대리모델(surrogate model) (9–10주차) · 문헌 후보 (11주차)

문제

폴더에 흩어진 결과는 학습에 바로 사용 불가

이번 주차

자율 탐색 파이프라인(autonomous exploration pipeline) 구조 수립 · 후보 생성 · 적재 · 품질 규칙 결정

파이프라인 6단계를 한 루프로 연결하는 주차 — 중심: 후보 생성(01 → 02) · 데이터 적재(03 → 04)

OBJECTIVE

12주차 학습목표

01 자율 탐색 파이프라인 6단계 · 모듈 경계(module boundary)를 실제 플랫폼 구조에 대응

02 첨가제 라이브러리(additive library) · 치환 레버(lever) · 조성 격자(composition grid)로 후보 생성

03 실험 ID = 기본 키(primary key)인 스키마(schema)에 결과 · 메타데이터(metadata) 적재 (PostgreSQL)

04 이상치(outlier) · 미수렴(unconverged) 결과의 플래그(flag) 처리 · 재현성 매니페스트(manifest) 기록

AGENDA

12주차 구성

12-1	파이프라인 구조	12분
12-2	후보 분자 생성	12분
12-3	PostgreSQL 데이터 큐레이션	16분
12-4	이상치 처리·재현성	10분

12 - 1

파이프라인 구조

12분 · 6단계 루프 · 모듈 경계 · 실제 플랫폼

12-1 · PIPELINE

파이프라인 = 6단계 루프

01 문헌 고찰 · 11주차

후보 분자 · 표적 범위 수집

설계 변수 결정

02 구조 생성 · 4주차

분자 조립 · 벌크 셀 구축

조성을 계산 가능한 계로 구성

03 MD 계산 · 5-8주차

물성 산출 · 결과 적재

데이터베이스 축적 시작 · 이론 = 2–3주차

04 대리모델 · 9-10주차

XGBoost+SHAP(Shapley 기여도) · GNN(그래프 신경망) · 불확실성

빠른 평가 함수 확보

05 능동학습 · 10주차

다음 계산 대상 선정

계산 예산 배분 결정

06 최적화 · 13주차

다목적 최적화 · 특징 재정련

추천 조성 · 개선된 표현 산출

06의 출력이 01의 입력으로 환류 — 파이프라인은 직선이 아니라 루프

이번 주차 — 01 → 02 사이 후보 생성과 03 → 04 사이 데이터 적재

주차 = 강의계획서 차시 기준 · 구조 생성 4-3~4-5 · MD 실행 5-1~5-4 · 물성 · 소재 분석 6–8주차 · 다음 장 모듈 대응과 동일

12-1 · ARCHITECTURE

모듈 경계와 인터페이스



인터페이스 고정
모듈 간 교환 = 파일 · DB 레코드만 — 내부 구현은 자유

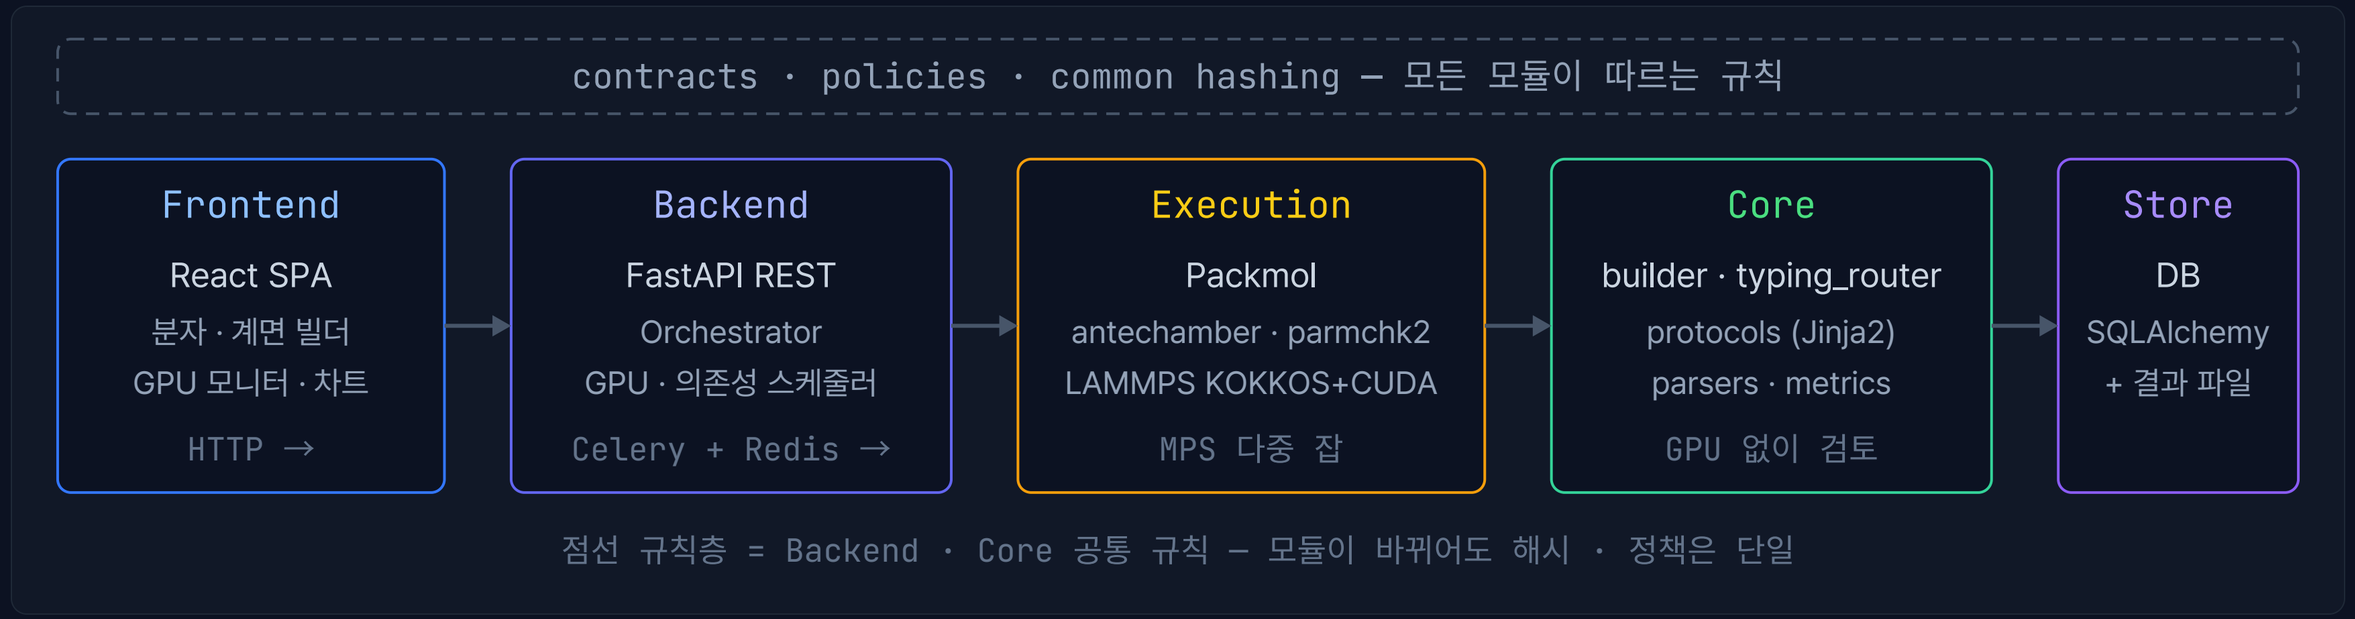
설정 주도
YAML 하나에 표적 · 제약 · 예산 · 티어(tier) 기재 → 전체 실행

부분 실행
단계별 단독 실행 가능 → 디버깅 용이

주차 = 강의계획서 차시 기준 · builder 4-3~4-5(토폴로지 · 초기 · 다층 구조) · runner 5-1~5-4(자동 스크립트 · 자기교정 · 배치 실행) · analyzer 6주차 물성 + 7 · 8주차 소재별 분석

12-1 · PLATFORM

실제 플랫폼 구성: 요청 · 조율 · 실행 · 저장



실험 한 건의 흐름

조성 명세 → 셀 구축 → 힘장 할당 → 프로토콜 · 티어 → GPU 슬롯 → LAMMPS → 로그 파싱 → 평균 ± SE → 구조화 DB

ML 단계 구조화 DB를 읽는 대리모델: 9주차 XGBoost+SHAP · 10주차 GNN — 능동학습(active learning)이 이 모델로 다음 계산 대상 선정

12-2

후보 분자 생성

12분 · 첨가제 라이브러리 · 치환 레버 · 조성 격자

12-2 · ADDITIVES

후보 생성의 입력: 첨가제 분자 라이브러리

고분자 개질제

SBS · SBR · EVA(스타이렌계 · 에틸렌계 고분자) — 탄성 회복 · 고온 강성

재생 · 연화제

식물유계 · 방향족 오일 — 노화 바인더 회복

부착 증진제

아민계 · 실란계 — 계면 박리 저항

나노 소재

탄소나노튜브 · 그래핀 · 나노실리카 · 나노클레이 — 강성 · 열전도

additive_library.csv

```
name, smiles, MW, logP, TPSA,
aromatic_frac, polar_atoms, ff, wt_range
SBS_seg, CC=CC..., 421, 6.8, 0.0,
0.38, 0, gaff2, 1-6
silane_A, CO[Si](OC)..., 222, 1.4, 45.5,
0.00, 4, gaff2+clayff, 0.2-1.0
```

기술자(descriptor) 표현

분자량 · logP(분배계수) · TPSA(위상 극성 표면적) · 방향족 분율 — 후보 생성의 설계 변수

힘장 표시

첨가제별 필요 힘장(force field) 조합 사전 기재 → 5주차 생성기가 검사

함량 범위

실무 배합 범위를 벗어난 wt%는 탐색 공간에서 제외

플랫폼 21종 additive_catalog 21종 중 조성 격자 투입 5종 = SBS 3:7 · 리그닌(Lignin) · 실리카(SiO2) · CNT · 그래핀(Graphene) · 위 네 카드 = 첨가제 계열 일반 분류

12-2 · SUBSTITUTION

골격 고정 · 치환 레버로 후보 생성

01 라이브러리

Li & Greenfield 12분자 골격

포화 2 · 방향족 2 · 레진 5 · 아스팔텐 3 — 고리계 · 헤테로원자 유지

+ 13번째 고황 아스팔텐 C47H68S3

02 정수 레버 격자

k	아스팔텐 알킬사슬	{0, 12, 16}
a	방향족 메틸치환	{0, 2}
s	티오에터(thioether) 추가	{0, 1, 2}

3 × 2 × 3 = 18개 격자점마다 분자 개수 최적화

03 생성 직후 검사

화학 안정성 — 라디칼 0 · 긴장고리(strained ring) 없음 · 생성가능성

SARA(포화분 · 방향족 · 레진 · 아스팔텐) 역할 — 아스팔텐이면 다환방향족 + 헤테로원자 + 알킬곁사슬

검사 불통과 조합 = 후보에서 제외

절차 골격 분자 → RDKit로 레버 적용 → 안정성 · SARA 검사 → 분자 개수 최적화 → 후보 조성

결과 예 PG(Performance Grade) 64-22 · 76-22 · 82-22의 최적 레버 (k, a, s) = (16,2,1) · (16,2,0) · (16,0,2) — 등급별로 다른 후보 도출

12-2 · GRID

후보 조성 = 네 축 격자

바인더 × 3

AAA1 · AAK1 · AAM1

노화 × 3

NA · SA · LA (비노화 · 단기 노화 · 장기 노화)

첨가제 × 6

none · SBS · Lignin · SiO2 · CNT · Graphene

온도 × 12

213 – 433 K · 20 K 간격

곱하기 전에 거르는 조성 제약

아스팔텐	5 – 30 wt%
레진	10 – 50 wt%
방향족	10 – 60 wt%
포화	5 – 40 wt%
첨가제 합	≤ 10 wt% · 전체 100 ± 0.01

격자점 하나 = exp_id 하나

`A1_X1_LA_SiO2_313K_…`

바인더 · 계 크기 · 노화 · 첨가제 · 온도 · 해시

실제 코어 672건: 첨가제 4종은 108건씩 균형, SBS는 74건으로 미충족

크기 3 × 3 × 6 × 12 = 648개 격자점 — 전수 계산 대신 10주차 능동학습 · 13주차 최적화가 다음 계산 대상 선정

격자 648점 대 코어 672건: 648 = 첨가제 6종 × 108(바인더 3 × 노화 3 × 온도 12) 계획 기준 · 672 = 계산 완료 기록 = 648 − SBS 미충족 34(AAK1 · AAM1 각 17) + AAA1 무첨가 같은 조건 반복 58(94 − 36)

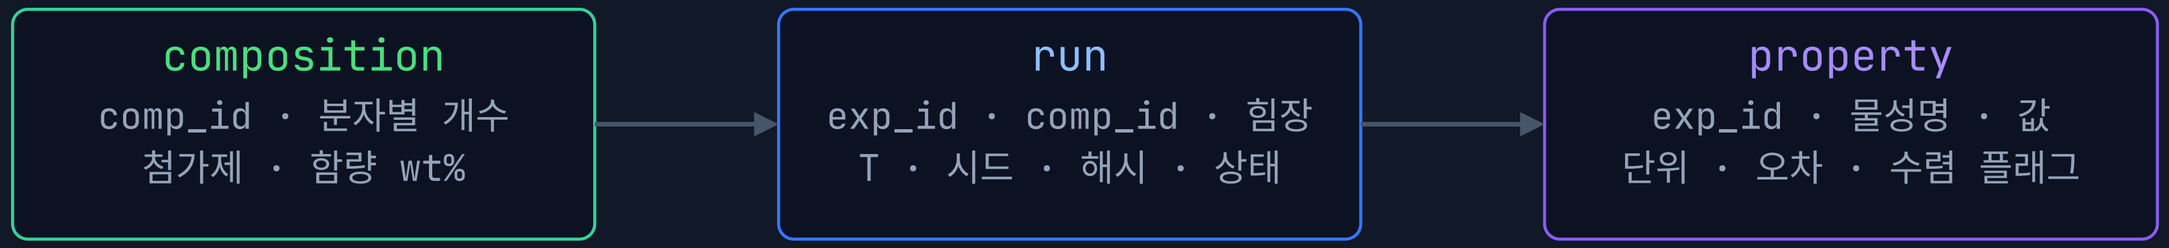
12 - 3

PostgreSQL 데이터 큐레이션

16분 · 세 테이블 · 플랫폼 ERD · 적재 계약

12-3 · SCHEMA

조성 · 실행 · 물성 세 테이블 분리



한 조성 → 여러 실행 → 실행마다 여러 물성 (1:N:N)

왜 나누나

조성 = 재사용 · 실행 = 반복 — 중복 감소 · 정합성 유지

키 규칙

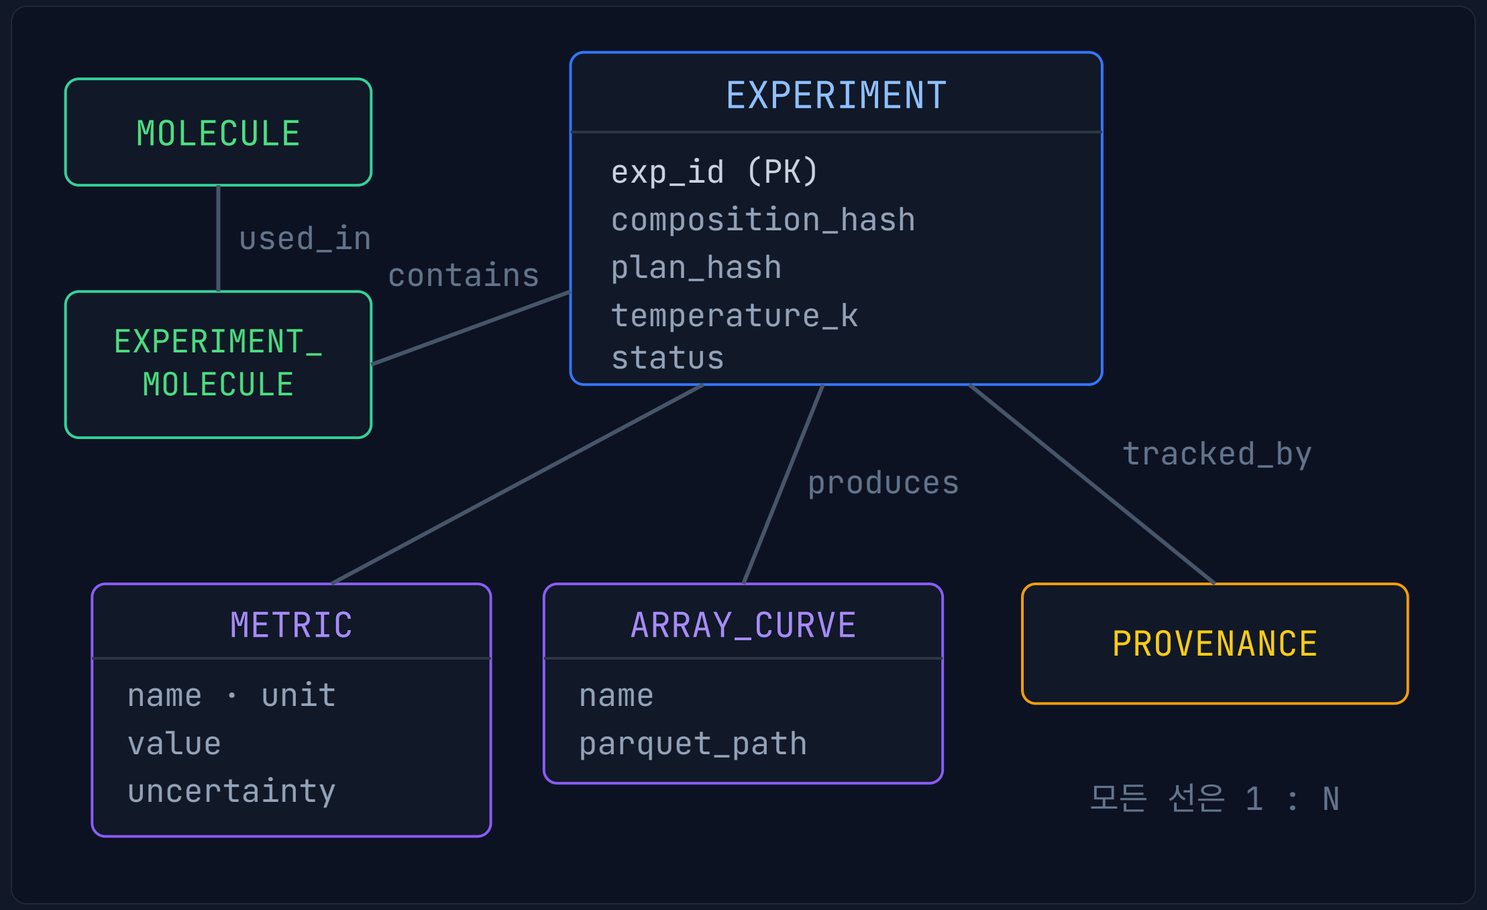
exp_id = 4주차 실험 ID 문자열 그대로 · 해시 포함

긴 형식(long format)

물성은 열이 아니라 행으로 — 새 물성이 생겨도 스키마를 바꾸지 않음

12-3 · ERD

개체-관계도(ERD): 실험 한 건 중심 구조



1급 컬럼

ML 피처 · 쿼리 필터 · 계보(provenance) 판정에 쓰는 값은 모두 컬럼으로

metadata_json

사람 메모 · 디버깅 정보 · 임시 태그만 — 정형화할 수 있으면 컬럼으로 승격

곡선은 파일로

응력-변형률 같은 배열은 parquet로 두고 DB에는 경로만

12-3 · INGEST

적재 조건: 계약 통과 값만 허용

fail-closed 저장

물성 이름은 레지스트리에 등록된 것만 · 단위와 namespace가 정의와 다르면 저장 거부

단일 진실원본 · SSOT(single source of truth)

학습 · 서빙 · 역설계 모두 단일 피처 생성기 사용

스키마 해시

피처 구성 변경 → 해시 변경 — 모델 저장 해시와 불일치 시 서빙 거부

PostgreSQL로 옮기면 (강의용 예시)

```
CREATE TABLE experiment (
  exp_id        text PRIMARY KEY,
  binder_type   text,
  comp_asphaltene_wt real NOT NULL,
  additive_type text,
  temperature_k real NOT NULL,
  run_tier      text NOT NULL,
  status        text NOT NULL,
  metadata_json jsonb
);
CREATE TABLE metric (
  exp_id text REFERENCES experiment,
  name   text REFERENCES metric_registry,
  value  double precision,
  uncertainty double precision
);
```

운영 DB = SQLite(SQLAlchemy) — PostgreSQL 이전 시 레지스트리 검사를 외래 키(foreign key) · CHECK 제약으로 DB가 직접 수행

12 - 4

이상치 처리·재현성

10분 · 적재 검사 · 이상치 사례 · 재현성 매니페스트

12-4 · QUALITY

적재 시점 자동 검사 목록

검사	기준	실패 시 처리
물리 범위	밀도 0.7 ~ 1.3 g/cm³ · 음수 점도 금지	invalid 플래그
수렴	평형 판정 통과 · 적분 평탄 구간 존재	unconverged 플래그
재현성	시드 간 편차가 보고 오차의 3배 이내	재계산 대기열
중복	같은 해시의 중복 적재 여부	최신 것만 유지
단위	물성별 단위 문자열 ↔ 사전 일치 여부	적재 거부

원칙 실패 결과도 삭제 없이 플래그만 부착 — 10주차 보충 B의 능동학습이 "어디서 실패하는가"를 학습에 사용

12-4 · OUTLIER

이상치 원인: 값이 아닌 계산 조건

01 증상

체적탄성률(bulk modulus) ~6.8e27 GPa · CED(응집에너지밀도) -3204 MJ/m³

K > 50 GPa 55건 · CED < 0 57건 — 모두 점도(전단) 런

02 원인

전단 런에 NPT(등온등압) 구간 없음 → 고정부피라 var(V) ≈ 0

$$K_T = k_B T \langle V \rangle / \mathrm{var}(V) \to \infty$$

폴백(fallback) 경로 + 물리 상한 검사 없음

03 처리

NPT가 없으면 계산하지 않음

0.1 – 50 GPa 범위 게이트

같은 런의 밀도 · MSD(평균제곱변위) · 점도는 유지

재백필 원본 로그에 NPT가 있는 결측 8건은 재계산으로 복원(backfill)

반대 사례 라벨이 빠진 retry 304건은 정상 실험 — 버렸다면 Lignin · SiO2 데이터 대부분을 잃음

원칙 이중 방어 — 계산 진입 조건과 물리 범위 게이트. 기존 저장값: NULL로 정정 또는 학습 시 범위 필터로 제외

12-4 · REPRODUCIBILITY

네 가지를 함께 고정

코드

git 커밋 해시 · 환경 파일(conda · requirements)

데이터

데이터셋 스냅샷 해시 · 폴드 인덱스 파일

모델

체크포인트 · 하이퍼파라미터 · 난수 시드

실행

LAMMPS 버전 · 힘장 파일 · 입력 해시

run_manifest.yaml

```
code:   { git: 9f3c1ab, env: env-2026-03.yml }
data:   { snapshot: ds_v4, sha256: 7b21… }
model:  { ckpt: gnn_v07.pt, seed: 42 }
run:    { lammps: 2Aug2023, ff: gaff2_v1, hash: a1b2c3d4 }
```

이번 주차 실습부터 모든 결과에 매니페스트 부착 — 13주차 최종 프로젝트 제출물에도 필수

PRACTICE

실습 · 후보 격자와 학습용 데이터셋 구축

PRACTICE

01 바인더 · 노화 · 첨가제 · 온도 격자 생성 · 조성 제약으로 필터링

02 6~8주차 결과를 세 테이블 스키마로 적재 (SQLite · PostgreSQL 또는 parquet)

03 RDKit으로 분자 기술자 계산 · 조성 가중 평균 구성

04 comp_id 기준 5-폴드 분할 · 폴드별 μ · σ 저장

05 품질 검사 스크립트 실행 · 플래그 통계 추출 · run_manifest 기록

DELIVERABLE

후보 격자 CSV · 데이터베이스 파일과 스키마 정의 · 폴드 인덱스 파일

특징 · 라벨 통계 요약 (개수 · 결측 · 플래그 비율)

9–10주차 학습 스크립트의 입력으로 그대로 사용

퀴즈 12주차

SUMMARY

12주차 정리

01 파이프라인 = 6단계 루프 — 모듈 간 교환은 파일 · DB 레코드만

02 후보 = 라이브러리 × 치환 레버 × 조성 격자 — 제약 밖 조합은 생성 단계에서 제외

03 조성 · 실행 · 물성 테이블 + 실험 ID = 데이터베이스의 기본 구조 — 계약 통과 값만 적재

04 이상치 = 삭제 없이 플래그 처리 · 결과 = 코드 · 데이터 · 모델 · 실행 동시 고정

퀴즈 12주차

다음 주차 — 자율 탐색 파이프라인 (2): 다목적 최적화 · LLM 에이전트와 통합 사례

APPX

부록 · 참고 자료

세 층위의 특징 · 누수를 만드는 세 가지 습관

APPENDIX · FEATURES

세 층위의 특징

층위	예시	성격
조성	SARA 분율 · 분자별 mol% · 첨가제 wt%	해석이 쉽고 설계 변수와 직결
분자	평균 분자량 · 방향족 탄소 분율 · H/C · 극성 원자 수 · TPSA	새 분자로 확장 가능
조건	온도 · 계 크기 · 힘장 · 티어	라벨 비교 가능성을 결정
구조 (선택)	RDF 첫 피크 · 자유부피 분율 · 응집체 크기	궤적이 있어야 계산 가능

금지 예측하려는 물성에서 유도한 값은 특징에서 제외 — 예: 점도 예측에 확산계수 입력 시 평가 왜곡

APPENDIX · LEAKAGE

누수를 만드는 세 가지 습관

01 전체로 정규화

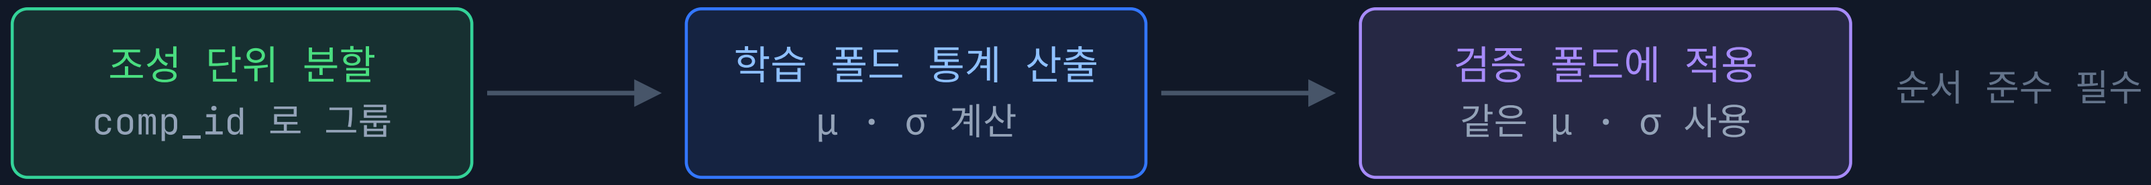
평균 · 표준편차 = 학습 폴드에서만 산출 · 검증에 그 값 적용

02 시드끼리 분리

같은 조성의 seed01은 학습 · seed02는 검증 — 검증 데이터가 학습 데이터와 사실상 동일

03 온도만 다른 행

같은 조성의 다른 온도 행이 양쪽에 들어가면 외삽 성능이 과대평가



APPENDIX · ORIGINAL TEXT · 1 / 2

이전 구성의 원문 문구

01	데이터 파이프라인과 특징 공학
02	적재 스키마 · 분자 기술자 · 정규화와 누수 · 품질 점검
03	실습 · 학습용 데이터셋 구축
04	MD 블록의 산출물 회고
05	스키마 · 특징 · 분할 규칙 결정 · 데이터셋 구성
06	파이프라인 6단계 중 03 → 04 사이를 연결하는 주차
07	실험 ID를 기본 키로 하는 결과 적재 스키마 설계
08	조성 · 분자 수준 기술자 정의 · 계산
09	정규화 시점 준수로 데이터 누수 방지
10	이상치 · 미수렴 결과를 걸러내는 품질 점검 자동화
11	결과 적재 스키마
12	조성 · 분자 기술자

APPENDIX · ORIGINAL TEXT · 2 / 2

이전 구성의 원문 문구

13	정규화와 데이터 누수 방지
14	데이터 품질 점검
15	실습 · 학습용 데이터셋 만들기
16	10주차 학습 스크립트가 이 파일을 그대로 판독
17	조성 · 실행 · 물성 세 테이블과 실험 ID가 데이터베이스의 기본 구조
18	특징은 조성 · 분자 · 조건 층위로 나누고, 라벨에서 유도한 값은 넣지 않음
19	분할 먼저 · 정규화 나중 — 순서 준수가 누수 방지의 전부